Presentación de la fase de preparación y procesamiento de datos del proyecto Smartpet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

10 de abril de 2026

Resumen

El presente informe detalla la fase de preparación y curación de datos para el proyecto SmartPet, un sistema de visión artificial basado en YOLOv11 diseñado para la detección de posturas caninas en entornos de propiedad horizontal mediante cámaras de CCTV. Dada la naturaleza del entorno, el dataset presenta desafíos geométricos significativos, como ángulos de cámara negativos y distorsiones de perspectiva. Se implementó un pipeline automatizado que preserva intencionalmente imágenes de fondo (background) y objetos distantes para reducir la tasa de falsos positivos. La limpieza de cajas delimitadoras (bounding boxes) se realizó mediante el método del Rango Intercuartílico (IQR) aplicado de forma independiente por clase, preservando la varianza morfológica natural. Adicionalmente, se desarrollaron dos transformaciones de variables o también denominadas meta-características espaciales: Perspectiva de Ángulo Negativo (NAP) y Densidad de Píxeles Informativos (IPD), permitiendo la depuración algorítmica del 1% del ruido basal severo. El resultado es un conjunto de datos depurado de 1,499 anotaciones, con un desbalance manejable (1.21:1), optimizado para el entrenamiento robusto del modelo.

Introducción

En el ámbito de la videovigilancia en propiedad horizontal, la detección automatizada de anomalías, específicamente las posturas de caninos (ej. clase defecating-dog), representa un desafío complejo para los modelos de Visión Artificial. Las cámaras CCTV suelen instalarse en posiciones elevadas, generando ángulos de captura picados (negativos) que distorsionan significativamente la escala, la relación de aspecto y la morfología aparente de los sujetos en función de su distancia focal.

Para que arquitecturas de detección de objetos de un solo disparo (one-stage detectors) como YOLOv11 logren un rendimiento óptimo y una alta capacidad de generalización, es imperativo contar con un pipeline de datos rigurosamente estructurado. Este informe documenta el proceso de Análisis Exploratorio de Datos (EDA), curación y Feature Engineering aplicado al dataset del proyecto SmartPet, garantizando que la red neuronal aprenda características anatómicas reales y no sesgos derivados del ruido estructural del entorno.

Pipeline de Limpieza de Datos

El proceso de curación se basó en un enfoque analítico para distinguir entre errores de anotación y varianza legítima del entorno CCTV:

Tratamiento de Valores Nulos y Background

Se identificaron 18 archivos de anotación sin coordenadas. En lugar de eliminarlos, se conservaron estratégicamente como imágenes de fondo (background) explícito. Esta práctica empírica es vital en YOLO para penalizar detecciones erróneas y mitigar la tasa de falsos positivos frente a distractores del entorno.

Figura 1

Distribución de registros con y sin anotaciones

```
Directorios de etiquetas encontrados: ['/content/drive/MyDrive/Proyecto Integrador MIA/DataSet/Dataset Dog and DogDef Balanced 07abr2026/Experimento Dataset Dog and DogDef Balanced.v1i.yolov8/test/labels', '/content/drive/M
### 7. Revisión de la Calidad de los Datos

**Valores Faltantes por Columna:**
```

	Count
class_id	18
x_center	18
y_center	18
width	18
height	18

```
Interpretación: Columnas como 'class_id', 'x_center', etc., con valores faltantes indican anotaciones incompletas o archivos de etiquetas vacíos para algunas imágenes. Esto puede llevar a que esas instancias no se usen en e

--------------------------------------------------

**Número de Filas Duplicadas Completas:** 0
No se encontraron filas duplicadas completas en el DataFrame de anotaciones.
```

Nota. Se observa en la imagen la proporción de imágenes con anotaciones válidas frente a aquellas sin coordenadas (*background*) o con anotaciones vacías, evidenciando la presencia de registros sin bounding boxes

Figura 2

Frecuencia de imágenes de fondo (background) en el dataset

```
Total de imágenes con archivos de anotación vacíos detectadas: 18

Nombres de las imágenes sin anotaciones:
1. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0005_jpg.rf.65bee473c8b4398b199031301cdeac44
2. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0003_jpg.rf.dfb329cfdf49c94823334c1e1cc7789b
3. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0006_jpg.rf.171399ff9da225f4eede72862f6fad63
4. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0052_jpg.rf.8c07df6f15fed24b96d09d7c87f3d0c3
5. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0002_jpg.rf.a14680f9a0b784da21c2bb271993d50c
6. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0065_jpg.rf.1e334a44c0af33760f8dc0bca44f34ea
7. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0000_jpg.rf.a9fcd287454ed16e7e223745884d7504
8. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0001_jpg.rf.84917edb886770397084586a624318ef
9. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0053_jpg.rf.cd4ac65c9c1c04c3574e45f41b8bc0c7
10. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0064_jpg.rf.c2f50ce62a03a58850c9dbf866ea1da6
11. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0062_jpg.rf.4062948b199bd0ba43590d586fe8fb69
12. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0063_jpg.rf.9acb439692b5cea7f82b9ecc98026be8
13. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0004_jpg.rf.2b9d1594c7a89dd15f90db8860f950a1
14. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0050_jpg.rf.e0421739295663a5af08738e1b799dcb
15. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0000_jpg.rf.ca9e8f19d55469643ea69510c1b73fce
16. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0001_jpg.rf.d47ed15749cb1a51b0dd4745fb44b656
17. WhatsApp-Video-2026-04-06-at-8_25_53-PM_mp4-0007_jpg.rf.53077cb8c09b05c63071b8c8dcf6d3a2
18. Dog-poop-caught-on-Security-Camera-twice-in-one-day_mp4-0029_jpg.rf.251bbfb51f171ed9e1aeff9efecac0ec


Se encontraron 18 imágenes en las carpetas. Generando visualización...
```

Nota. En la imagen se observan ejemplos de imágenes sin anotaciones, utilizadas como ejemplos negativos explícitos para mejorar la capacidad del modelo de discriminar objetos reales frente a ruido del entorno

De igual forma, el proceso de auditoría evidencia que el dataset no presenta registros duplicados, valores inconsistentes, registros anómalos ni missing values, lo que confirma su integridad y coherencia interna. Esta condición garantiza una base de datos confiable para el entrenamiento del modelo, reduciendo el riesgo de sesgos y errores durante la fase de aprendizaje.

Figura 3

Verificación de calidad de datos

```
Directorios de etiquetas encontrados: ['/content/drive/MyDrive/Proyecto Integrador MIA/DataSet/Dataset Dog and DogDef Balanced 07abr2026/Experimento Dataset Dog and DogDef Balanced.v11.yolov8/test/labels', '/content/drive/
### 7. Revisión de la Calidad de los Datos

**Valores Faltantes por Columna:**
```

	Count
class_id	18
x_center	18
y_center	18
width	18
height	18

```
Interpretación: Columnas como 'class_id', 'x_center', etc., con valores faltantes indican anotaciones incompletas o archivos de etiquetas vacíos para algunas imágenes. Esto puede llevar a que esas instancias no se usen en

---

**Número de Filas Duplicadas Completas:** 0
No se encontraron filas duplicadas completas en el DataFrame de anotaciones.

---

**Valores Inconsistentes (Fuera del rango esperado [0,1] para coordenadas/dimensiones, o ID de clase inválido):**
No se encontraron valores inconsistentes fuera del rango esperado en coordenadas, dimensiones o IDs de clase.

---

**Registros Anómalos (Outliers detectados por IQR 1.5x):**
No se detectaron outliers significativos mediante el método IQR en las dimensiones de las bounding boxes.

---

Número de imágenes con archivos de anotaciones vacíos o sin anotaciones: 18
Número de imágenes sin un archivo de anotación correspondiente: 0
```

Nota. En la imagen se observa la validación del dataset, confirmando la ausencia de registros duplicados, valores inconsistentes, anomalías estructurales en las anotaciones y la no existencia de missing values.

Auditoría de Formatos Incorrectos en las Variables

Se auditaron las variables y sus formatos evidenciando como aparece a continuación que no es necesario efectuar correcciones adicionales en esta vía.

Figura 4

Auditoría de tipos de datos y consistencia estructural de las variables del dataset

```
### Tipología de Datos de las Variables del Dataset
```

Variable	Tipo de Dato (Pandas)
image_filename	object
class_id	float64
x_center	float64
y_center	float64
width	float64
height	float64
has_annotations	bool
area	float64
aspect_ratio	float64
class_label	object

```
### Conteo de Valores con Tipo de Dato Diferente al Esperado

No se encontraron valores con tipos de datos diferentes al esperado en ninguna de las columnas evaluadas.
La tipología de los datos es consistente.
```

Nota. La figura presenta la tipología de datos de las variables del dataset según su representación en *Pandas*, junto con la verificación de consistencia en los tipos de datos. No se identificaron discrepancias entre los tipos esperados y los observados, lo que confirma la integridad estructural del conjunto de datos.

Gestión de Outliers mediante IQR Específico de Clase

Se detectaron 43 valores atípicos en la relación de aspecto (`aspect_ratio`) para la clase `dog` y 9 para `defecating-dog`. Se aplicó el método de Rango Intercuartílico (1.5x IQR) agrupado por clase. Esta decisión metodológica permite limpiar cajas significativamente diferentes, sin destruir la representación de posturas elongadas naturales o distorsiones causadas válidamente por el ángulo de la cámara.

Figura 5

Detección y tratamiento de valores atípicos en relación de aspecto mediante IQR por clase

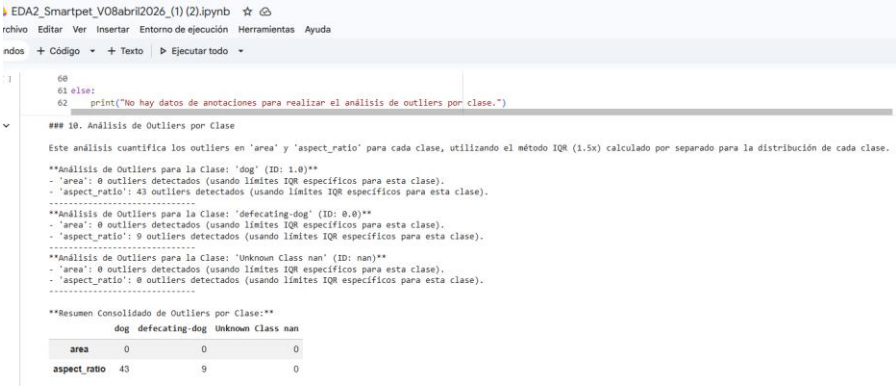

Nota. La figura muestra la identificación de outliers en la variable *aspect_ratio* utilizando el método de Rango Intercuartílico (1.5×IQR), aplicado de forma independiente por clase, permitiendo eliminar errores de anotación sin afectar la variabilidad geométrica legítima

Depuración Estructural

Se aseguró la validación de los datos y su depuración estructural para facilitar la fase de modelado.

Flujo de Limpieza

Dentro del notebook de colab se ha implementado el siguiente procedimiento reproducible que permite ejecutar la secuencia de pasos aplicados al dataset:

Figura 6

Pipeline automatizado de limpieza y curación de datos

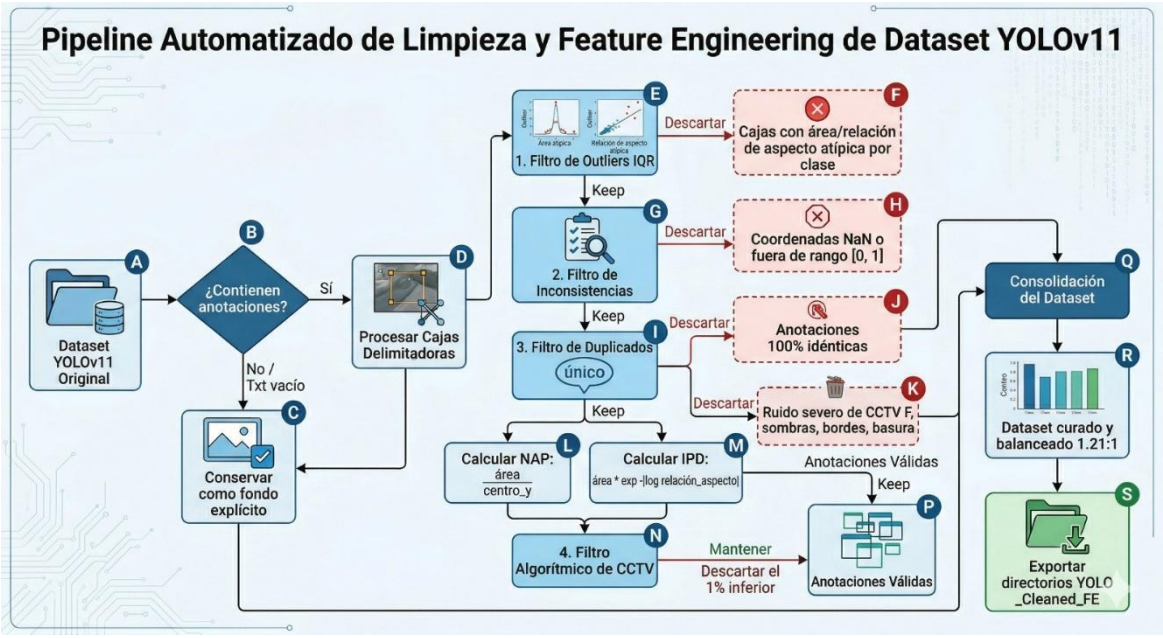

Nota. Este diagrama ilustra el flujo reproducible implementado en el notebook de Google Colab para la limpieza del dataset, incluyendo validación de datos, eliminación de outliers, cálculo de nuevas variables y estructuración final del conjunto de datos.

Tabla 1

Reglas de limpieza y decisiones metodológicas aplicadas en el pipeline de curación de datos

Problema Detectado / Condición	Solución Aplicada (Regla en el Pipeline)	Justificación Técnica (Metodología)
1. Ausencia de objetos objetivo (Imágenes de fondo)	Retención explícita: Se conservan las imágenes que poseen archivos de anotación (.txt) vacíos.	Las imágenes sin *bounding boxes* actúan como *background images* (imágenes negativas). Son cruciales para enseñarle al modelo a reconocer el entorno estático y reducir la tasa de falsos positivos.

Problema Detectado / Condición	Solución Aplicada (Regla en el Pipeline)	Justificación Técnica (Metodología)
2. Bounding boxes microscópicos	Retención condicionada: Se conservan las imágenes y anotaciones cuyas áreas relativas son cercanas a cero.	En el dominio específico de cámaras de seguridad (CCTV), los caninos suelen ser captados a largas distancias. Eliminar estas áreas suprimiría la capacidad de detección lejana del modelo.
3. Valores atípicos (Outliers) en métricas espaciales	Filtrado dinámico por clase (Script IQR): Se eliminan filas donde el área y aspect_ratio estén fuera del rango $Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$. El cálculo se aísla por class_id.	Aplicar el IQR de forma independiente por clase permite eliminar verdaderas anomalías estadísticas sin destruir las variaciones geométricas legítimas propias de cada categoría.
4. Duplicidad exacta de registros	Deduplicación estricta: Se eliminan los registros que presentan un nivel del 100% de coincidencia, conservando un único ejemplar.	Previene la fuga de datos (*data leakage*) entre los conjuntos de entrenamiento y validación, y mitiga el riesgo de sobreajuste (*overfitting*).
5. Archivos huérfanos (Ruptura estructural)	Eliminación en cascada: Se eliminan las imágenes que no tienen su correspondiente archivo .txt, así como los .txt sin imagen asociada.	Garantiza la integridad referencial y estructural del dataset. Arquitecturas como YOLO requieren pares exactos (Imagen-Etiqueta) para compilar el grafo de entrenamiento.

Nota. La tabla presenta las principales condiciones problemáticas identificadas en el dataset, junto con las reglas aplicadas en el pipeline de limpieza y su respectiva justificación técnica. Estas decisiones permiten preservar la variabilidad estructural del entorno CCTV, al tiempo que eliminan ruido y errores de anotación que podrían afectar el desempeño del modelo.

Feature Engineering Avanzado

Para discriminar anatómica y espacialmente a los sujetos reales del ruido del piso (sombras, hojas, baldosas), se extrajeron dos meta-características algorítmicas de las dimensiones relativas de las bounding boxes a partir de las variables originales:

Perspectiva de Ángulo Negativo (NAP)

Modelada matemáticamente como area / y_center. En la perspectiva CCTV, un objeto más cercano al lente (mayor coordenada y_center hacia el borde inferior) debe proyectar un área mayor. Los registros que violan esta progresión geométrica sugieren fuertemente ruido a nivel del suelo.

Densidad de Píxeles Informativos (IPD)

Calculada como area * exp(-|log(aspect_ratio)|). Esta métrica evalúa la compacidad del objeto, penalizando severamente cajas delimitadoras que poseen área pero presentan morfologías inverosímiles (excesivamente filiformes o planas), filtrando así bordes de acera o cables mal etiquetados.

Impacto

El filtrado del percentil inferior (1%) de las distribuciones NAP e IPD permitió descartar automáticamente 16 anotaciones de ruido crítico, resultando en un corpus final de 1,499 anotaciones de alta fidelidad.

Variables Utilizadas

En la tabla a continuación encontramos el listado de variables que utilizamos en el proyecto, incluyendo las nuevas dos variables creadas, con su respectiva descripción:

Tabla 2

Descripción de variables y características del dataset SmartPet

Variable / Característica	Tipo de Dato	Rango / Valores Esperados	Descripción / Significado
image_filename	String	N/A	Identificador único del archivo de imagen (generalmente sin la extensión .jpg o .png). Llave principal de cruce.
class_id	Float (Categórica)	0.0, 1.0, NaN	Identificador numérico de la clase detectada por la bounding box. NaN se usa para representar imágenes de fondo (background) intencionales sin detecciones.
class_name	String	'defecating-dog', 'dog'	Nombre legible de la clase correspondiente al identificador class_id.

Variable / Característica	Tipo de Dato	Rango / Valores Esperados	Descripción / Significado
x_center	Float	[0.0, 1.0]	Coordenada X (horizontal) del punto central del bounding box, normalizada respecto al ancho total de la imagen.
y_center	Float	[0.0, 1.0]	Coordenada Y (vertical) del punto central del bounding box, normalizada respecto al alto total de la imagen.
width	Float	(0.0, 1.0]	Ancho del bounding box, normalizado respecto al ancho total de la imagen.
height	Float	(0.0, 1.0]	Alto del bounding box, normalizado respecto al alto total de la imagen.
has_annotations	Boolean	True, False	Bandera (flag) que indica si el registro corresponde a una imagen que contiene al menos un objeto anotado.
area	Float	(0.0, 1.0]	Área relativa del bounding box calculada geométricamente como width * height. Mide la proporción de la imagen ocupada por la detección.
aspect_ratio	Float	> 0	Relación de aspecto morfológica (width / height). Valores > 1 indican objetos horizontalmente estirados; < 1 indican objetos verticalmente alargados.
NAP (Feature Eng.)	Float	> 0	Perspectiva de Ángulo Negativo (Negative Angle Perspective): Relación empírica calculada como area / y_center. Modela la profundidad simulada de la cámara CCTV. Valores muy bajos revelan ruido basal.
IPD (Feature Eng.)	Float	> 0	Densidad de Píxeles Informativos (Informative Pixel Density): Métrica de compacidad anatómica calculada como `area * exp(-

Nota. La tabla presenta las variables utilizadas en el proyecto, incluyendo características originales y variables derivadas mediante *feature engineering* (NAP e IPD), junto con su tipo de dato, rango esperado y significado dentro del contexto del modelo de detección.

Análisis de Correlaciones

Al realizar el análisis de correlaciones, hemos logrado identificar dependencias entre las variables y evaluar posibles redundancias o patrones relevantes para el modelado. En primer lugar, se observa una correlación positiva alta entre el área y el ancho (r = 0.89), así como entre el área y el alto (r = 0.87), lo cual resulta consistente con la definición

geométrica del área como el producto de ambas dimensiones. Estos resultados indican que el área está fuertemente determinada por el ancho y el alto, lo que sugiere una posible redundancia de información entre estas variables.

Adicionalmente, se identifica una correlación positiva moderada entre el ancho y el alto (r = 0.67), lo que sugiere que las cajas delimitadoras tienden a crecer de manera proporcional en ambas dimensiones. Este comportamiento indica que una proporción significativa de los objetos mantiene una relación relativamente equilibrada entre su ancho y su altura.

En cuanto a la relación de aspecto, se observa una correlación positiva moderada con el ancho (r = 0.48) y una correlación negativa débil con el alto (r = -0.21). Estos resultados son coherentes con la definición de la relación de aspecto como el cociente entre el ancho y el alto, lo que implica que un incremento en el ancho tiende a aumentar dicha relación, mientras que un incremento en el alto tiende a reducirla.

Por otra parte, la correlación entre el área y la relación de aspecto es baja (r = 0.10), lo que indica que el tamaño de los objetos no está significativamente relacionado con su forma. Este hallazgo sugiere que el dataset presenta una diversidad geométrica adecuada, en la que objetos de distintos tamaños pueden exhibir distintas proporciones.

Estos resultados nos permiten ver que las variables relacionadas con el tamaño (ancho, alto y área) presentan una fuerte interdependencia, mientras que la relación de aspecto captura una dimensión complementaria asociada a la forma de los objetos. Esta diferenciación es relevante en el contexto de modelos de detección de objetos, ya que implica la necesidad de representar de manera adecuada tanto la escala como la geometría de los objetos para lograr un desempeño óptimo.

Figura 7

Matriz de correlación de las dimensiones de las cajas delimitadoras

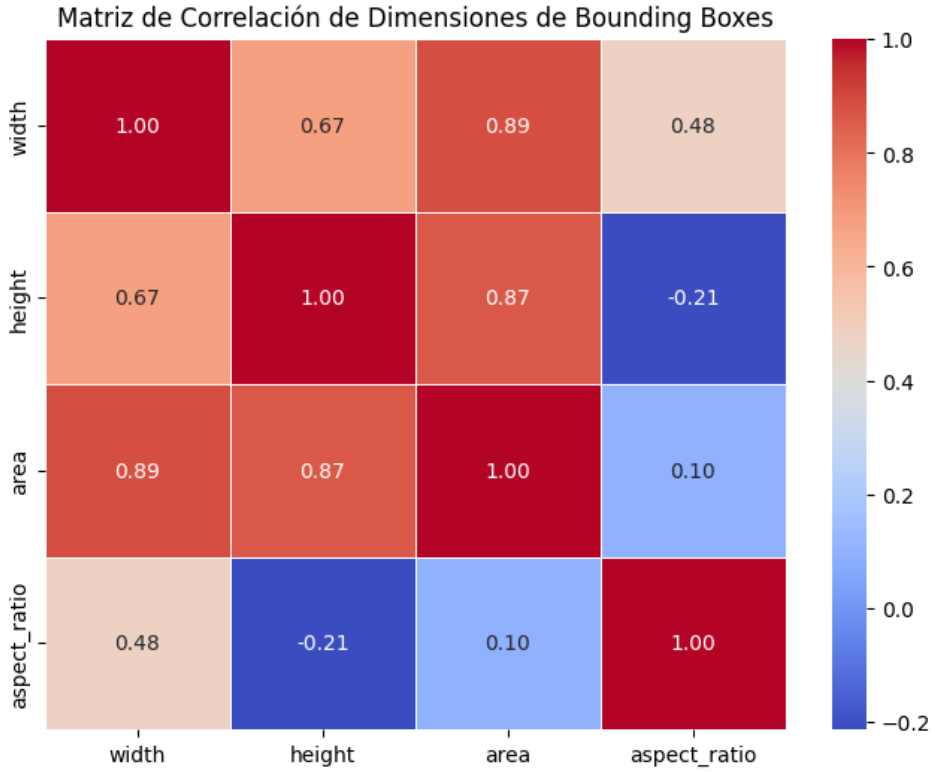

Nota. La figura presenta la matriz de correlación de Pearson entre las variables ancho (*width*), alto (*height*), área (*area*) y relación de aspecto (*aspect_ratio*), evidenciando dependencias estructurales y posibles redundancias entre variables geométricas.

Relaciones entre Variables

Al realizar el análisis de relaciones entre variables nos permite identificar patrones que son estructurales, así como posibles diferencias entre clases.

En primer lugar, se observa una relación positiva clara entre el ancho (*width*) y el alto (*height*), evidenciada por una distribución diagonal ascendente en los diagramas de dispersión. Este patrón confirma que las cajas delimitadoras tienden a crecer de manera proporcional en ambas dimensiones, lo cual es consistente con la correlación moderada

previamente identificada entre estas variables. Asimismo, la relación entre área (*area*) y las variables ancho y alto muestra una estructura rectangular bien definida, donde el área aumenta conforme crecen ambas dimensiones. Este comportamiento refleja la dependencia directa del área respecto a dichas variables, y evidencia una distribución coherente con su definición geométrica.

Por otra parte, la relación entre la relación de aspecto (*aspect_ratio*) y las demás variables presenta una mayor dispersión. En particular, se identifica una tendencia inversa entre la relación de aspecto y el alto, donde valores altos de altura tienden a asociarse con relaciones de aspecto más bajas. En contraste, la relación entre el ancho y la relación de aspecto es más difusa, aunque con una ligera tendencia positiva.

Un aspecto relevante del análisis es la superposición entre las clases *dog* y *defecating dog* en la mayoría de las combinaciones de variables. Si bien la clase *defecating dog* tiende a concentrarse en regiones más específicas —especialmente en términos de área y relación de aspecto—, no se observa una separación lineal clara entre las clases. Esto sugiere que las variables geométricas por sí solas no son suficientes para discriminar completamente entre ambas categorías. Adicionalmente, en las distribuciones univariadas (diagonal de la figura), se evidencia que la clase *defecating dog* presenta una mayor concentración en valores intermedios de ancho, alto y área, así como una distribución más estrecha en la relación de aspecto. En contraste, la clase *dog* muestra una mayor dispersión, lo que indica una mayor variabilidad en tamaño y forma.

Como conclusión, podemos abstraer que la clase *defecating dog* presenta características más homogéneas, mientras que la clase *dog* exhibe una mayor diversidad geométrica. Desde la perspectiva del modelado, esta superposición entre clases implica que el modelo de detección deberá apoyarse no solo en características geométricas, sino también en patrones visuales más complejos asociados al contexto y la postura del objeto.

Figura 8

Relaciones entre las dimensiones de las cajas delimitadoras (bounding boxes) por clase

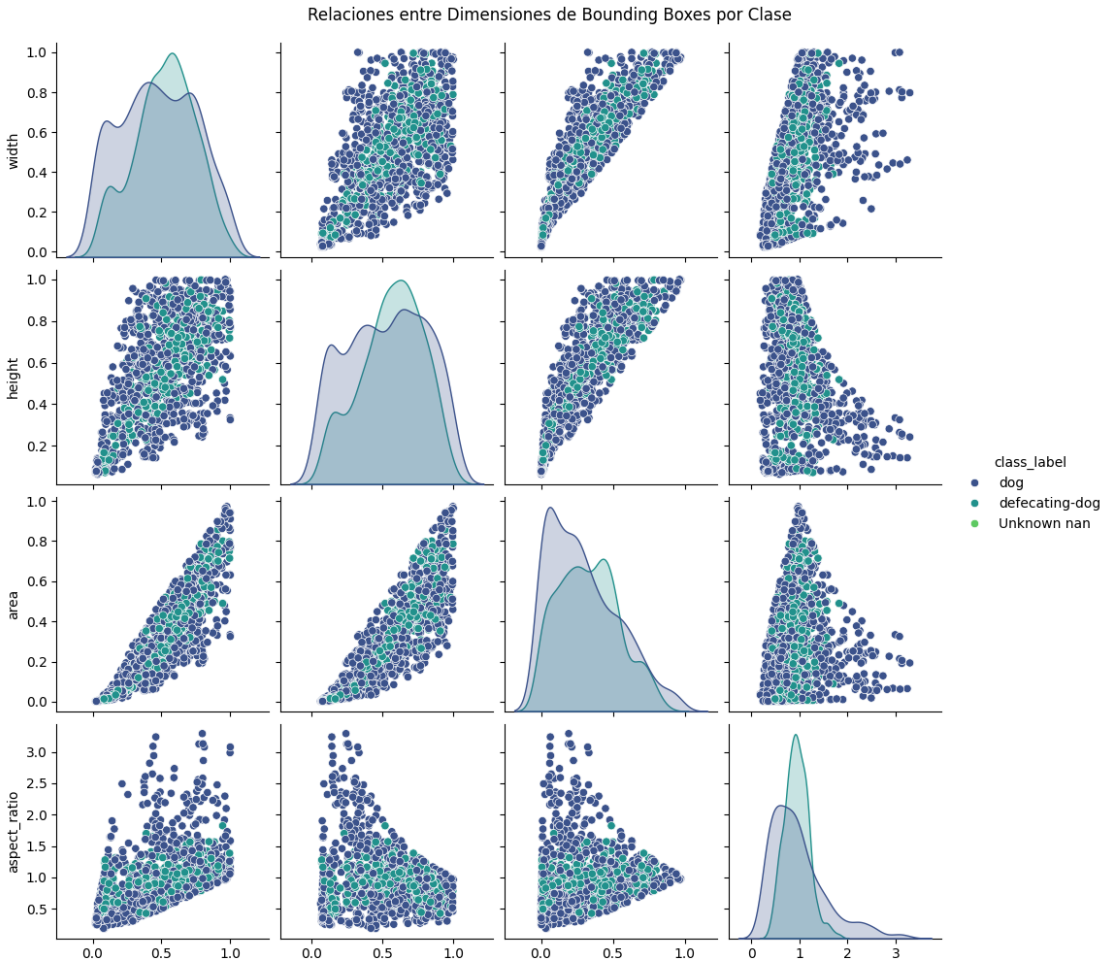

Nota. La figura presenta las relaciones bivariadas entre las variables geométricas mediante diagramas de dispersión, diferenciadas por clase, incluyendo distribuciones de densidad (KDE) en la diagonal..

Mediante la inclusión de las variables transformadas de manera algorítmica y de acuerdo con el siguiente gráfico, puede inferirse el ajuste más fino de los datos en términos de outliers como se identifica en las distribuciones de los datos después del filtro, desde

donde se infiere que el modelo podrá aprender y generalizar de mejor manera en virtud de una disminución significativa del ruido basal.

Figura 9

Distribución de variables geométricas posterior al filtrado mediante características NAP e IPD

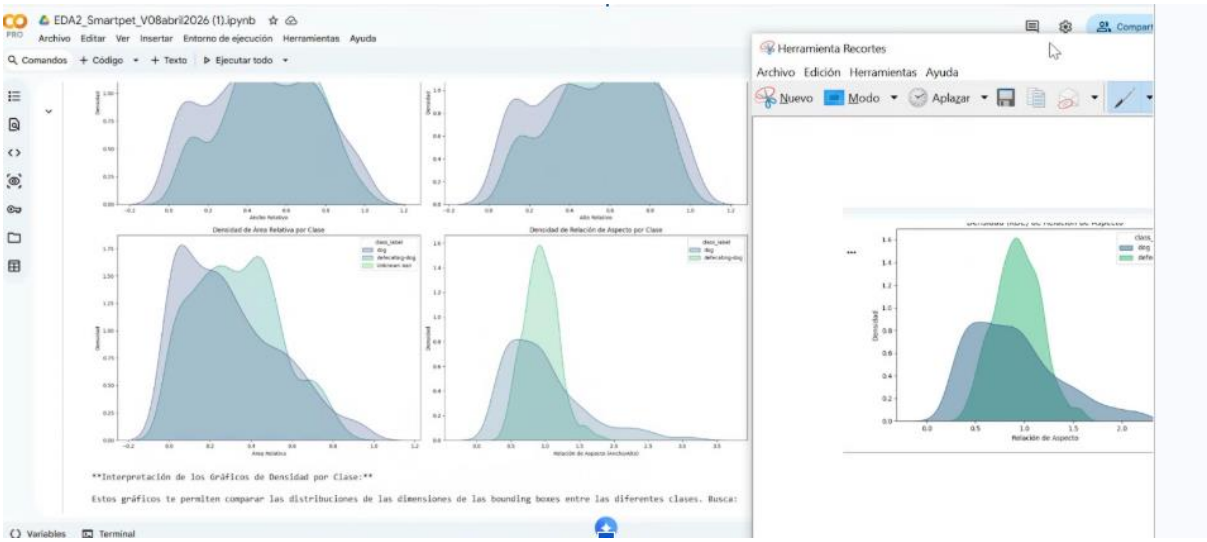

Nota. La figura presenta la distribución de las variables geométricas del dataset tras la aplicación de las transformaciones NAP e IPD y el filtrado del percentil inferior, evidenciando una reducción del ruido basal y una mayor coherencia en la estructura de los datos

La Figura 9 evidencia el impacto del proceso de *feature engineering* y depuración sobre la distribución de los datos. Se observa una reducción significativa de valores extremos y una mayor concentración en rangos representativos, lo que indica una mejora en la calidad estructural del dataset. Este comportamiento sugiere que el modelo podrá aprender patrones más consistentes y reducir la influencia de ruido asociado a artefactos del entorno.

Estrategias de Balanceamiento

El análisis de distribución de clases reveló un total de 821 instancias para la clase mayoritaria (`dog`) y 676 para la minoritaria (`defecating-dog`), excluyendo el fondo. Esto representa una proporción de 1.21:1. Teóricamente, este es un nivel de desbalance leve a moderado. Se determinó que arquitecturas robustas como YOLO pueden manejar esta disparidad inherentemente a través de su función de pérdida. Por consiguiente, se desestimó la aplicación inmediata de técnicas de sobremuestreo destructivo o generación sintética invasiva, previniendo el sobreajuste (*overfitting*).

Figura 10

Distribución de clases en el dataset

Nota. La figura muestra la distribución de frecuencias de las clases *dog* y *defecating-dog*, evidenciando un desbalance leve con una proporción aproximada de 1.21:1.

Análisis de Distribuciones

Según las métricas evidenciadas en las gráficas KDE del notebook, el comportamiento es el siguiente:

Ancho Relativo (width)

- Forma: La distribución parece ser bimodal o ligeramente multimodal, con picos alrededor de 0.3-0.4 y 0.7-0.8. Esto sugiere que existen dos grupos principales de

objetos en términos de su ancho relativo. Puede haber objetos pequeños/medianos y objetos grandes en tu dataset.

- Concentración: La mayoría de los valores se concentran en los rangos de los picos mencionados, mostrando menos densidad en los anchos intermedios. Hay una concentración notable en el rango medio-alto.
- Valores Extremos: Hay una cola hacia valores muy bajos (objetos muy estrechos) y algunos objetos que ocupan casi todo el ancho (valores cercanos a 1), pero la distribución general no muestra una asimetría extrema.

Alto Relativo (height)

- Forma: Similar al ancho, esta distribución también muestra características bimodales, con concentraciones alrededor de 0.4-0.5 y 0.7-0.8. Esto podría indicar diferentes tamaños de objetos o diferentes orientaciones típicas.
- Concentración: Los altos se concentran en los rangos de los picos. La densidad es menor en los altos intermedios.
- Valores Extremos: Se observan objetos muy bajos (poca altura relativa) y objetos que llenan casi toda la altura de la imagen. La curva KDE ayuda a suavizar y visualizar mejor estos grupos.

Área Relativa (area)

- Forma: La distribución del área está claramente sesgada a la derecha (asimetría positiva), con la mayoría de los objetos teniendo áreas pequeñas a medianas. La curva de densidad disminuye rápidamente a medida que el área aumenta.
- Concentración: La inmensa mayoría de los objetos se concentra en áreas relativas bajas, posiblemente por debajo de 0.5. Esto es común en datasets de detección de objetos, donde los objetos suelen ocupar solo una fracción de la imagen.
- Valores Extremos: La larga cola hacia la derecha indica la presencia de objetos muy grandes, que fueron detectados como outliers en el análisis anterior. Estos objetos son menos frecuentes, pero existen.

Relación de Aspecto (aspect_ratio)

- Forma: La distribución de la relación de aspecto muestra un pico principal cerca de 1 (objetos cuadrados o casi cuadrados) y una cola que se extiende hacia valores más altos (objetos anchos y bajos) y, en menor medida, hacia valores más bajos (objetos altos y estrechos). Parece ser sesgada a la derecha.
- Concentración: Una gran parte de las anotaciones tienen una relación de aspecto cercana a 1, indicando objetos con proporciones equilibradas. La concentración disminuye a medida que la relación de aspecto se aleja de 1.
- Valores Extremos: Los valores en los extremos de la cola (muy bajos o muy altos) corresponden a los outliers de relaciones de aspecto extremas, como objetos muy largos y delgados, o muy cortos y anchos. Estos son menos comunes pero presentes y representan un desafío para el modelo.

Figura 11

Distribución de de las dimensiones de las cajas delimitadoras mediante histogramas y curvas KDE

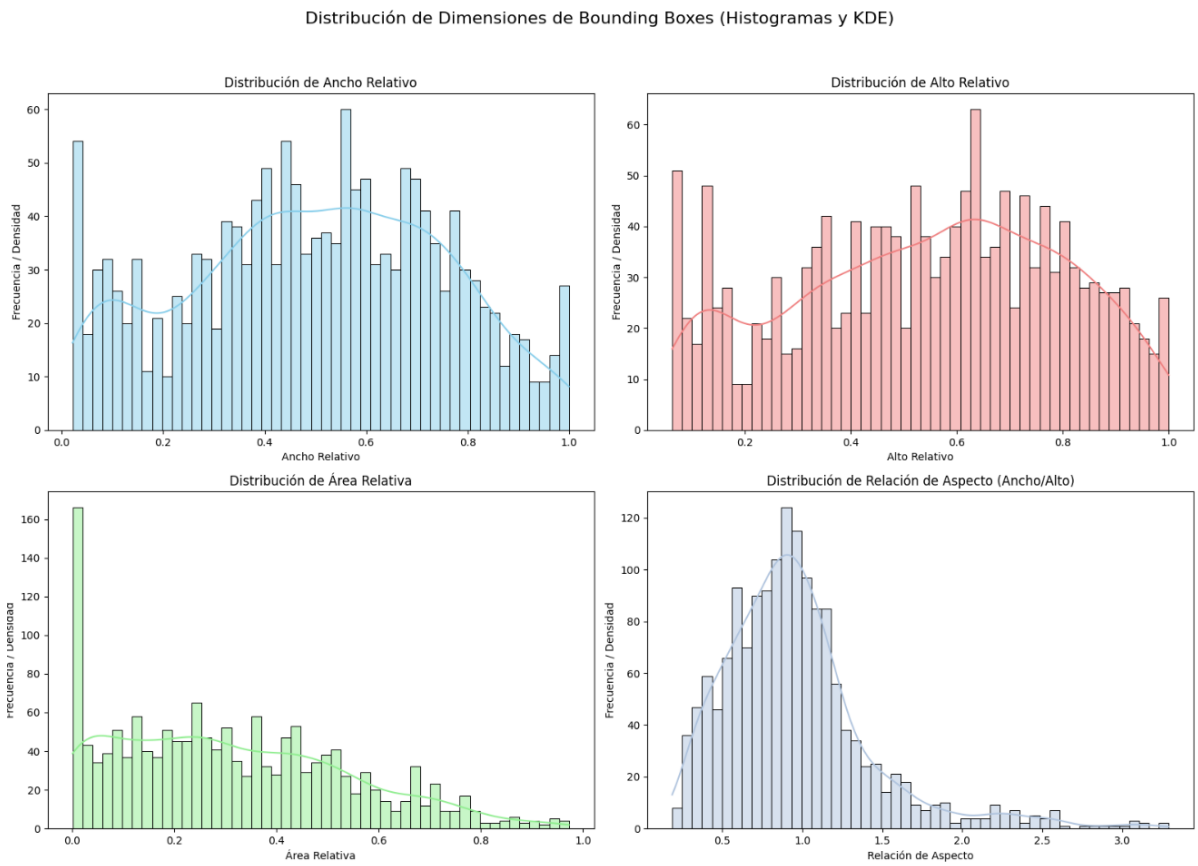

Nota. La figura presenta la distribución de las variables ancho, alto, área y relación de aspecto utilizando histogramas y curvas KDE, permitiendo analizar la forma, dispersión y asimetría de las dimensiones geométricas

Dada la distribución previamente analizada, se procedió a identificar y visualizar aquellas instancias cuyas cajas delimitadoras presentan áreas relativas cercanas a cero, con el objetivo de realizar una inspección cualitativa del comportamiento de estos registros. Este análisis permite validar si dichos valores corresponden a condiciones legítimas del dominio, como pueden ser objetos captados a gran distancia en escenarios CCTV, o si por el contrario representan ruido estructural, errores de anotación o artefactos del entorno, por ejemplo, sombras, texturas del suelo o elementos no relevantes.

La inspección visual de estas instancias resulta fundamental dentro del enfoque metodológico adoptado, ya que permite asegurar que no se eliminen datos que aunque sean extremos desde una perspectiva numérica, son representativos del fenómeno real que el modelo debe aprender.

Figura 12

Ejemplos de imágenes con bounding boxes de área relativa cercana a cero

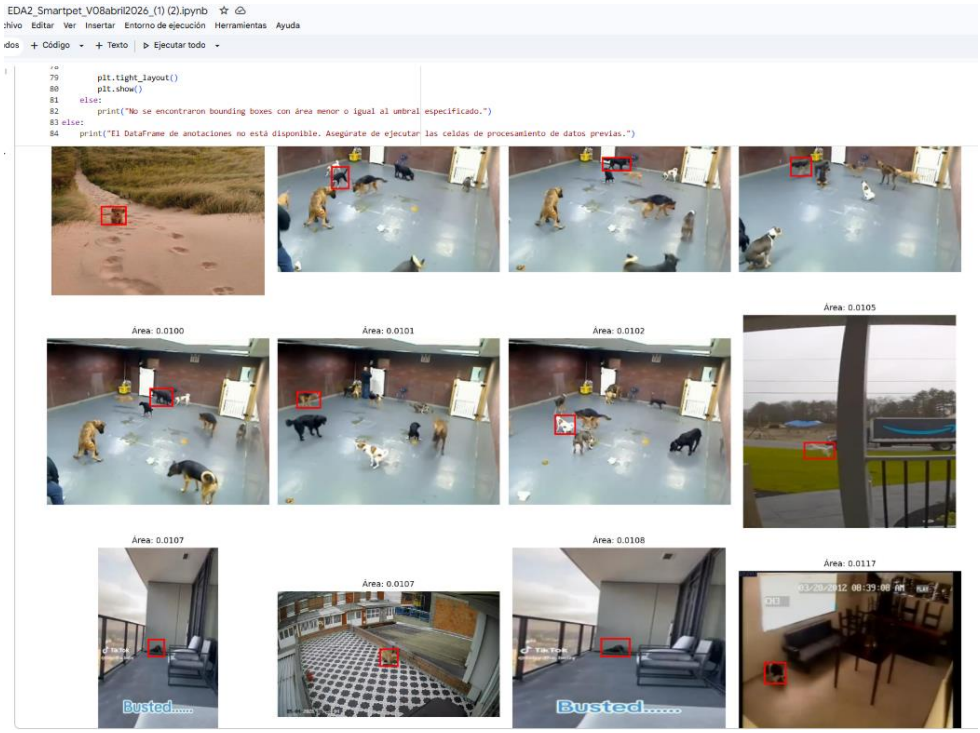

Nota. La figura muestra ejemplos de imágenes cuyas cajas delimitadoras presentan áreas relativas muy bajas, permitiendo inspeccionar visualmente instancias potencialmente problemáticas asociadas a objetos distantes, ruido del entorno o errores de anotación.

Distribución por Clases

Al realizar el análisis, podemos comprender las características geométricas de los objetos presentes en el dataset y su posible impacto en el desempeño del modelo de detección. En primer lugar, en la distribución del ancho relativo, se observa que la clase *dog* presenta una mayor dispersión en comparación con la clase *defecating dog*, lo que indica una mayor variabilidad en el tamaño horizontal de los objetos detectados. Por su parte, la clase *defecating dog* muestra una mayor concentración en valores intermedios, lo que sugiere que los objetos de esta clase tienden a presentar dimensiones más consistentes.

De manera similar, en la distribución del alto relativo, la clase *dog* evidencia una mayor variabilidad, mientras que la clase *defecating dog* se concentra en un rango más acotado. Este comportamiento puede estar asociado a la postura específica del perro

durante el acto de defecar, la cual genera patrones más homogéneos en la dimensión vertical.

En cuanto al área relativa, se identifica que la clase *dog* presenta una mayor densidad en áreas pequeñas, lo que sugiere la presencia de múltiples instancias de objetos de menor tamaño, posiblemente debido a variaciones en la distancia o el encuadre. En contraste, la clase *defecating dog* se distribuye hacia áreas mayores, indicando que estos objetos suelen ocupar una proporción más significativa de la imagen.

Finalmente, la distribución de la relación de aspecto (ancho/alto) revela diferencias importantes entre ambas clases. La clase *defecating dog* presenta una alta concentración alrededor de valores cercanos a 1, lo que indica que las cajas delimitadoras tienden a ser aproximadamente cuadradas. Por el contrario, la clase *dog* muestra una mayor dispersión, reflejando una diversidad de formas y orientaciones.

En conjunto, estos resultados evidencian que la clase *defecating dog* posee características geométricas más homogéneas, mientras que la clase *dog* presenta una mayor variabilidad en tamaño y forma. Esta diferencia puede influir en el desempeño del modelo de detección, ya que clases más homogéneas suelen ser más fáciles de aprender, mientras que clases con alta variabilidad requieren una mayor capacidad de generalización por parte del modelo.

Figura 13

Distribución de las dimensiones de las cajas delimitadoras por clase

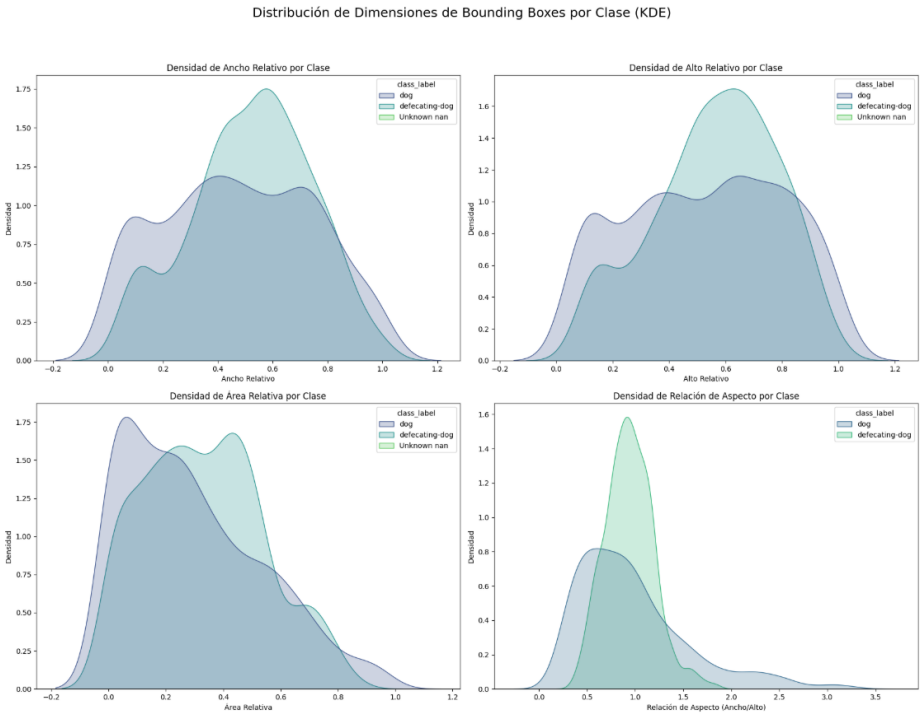

Nota. La figura presenta la distribución de las dimensiones relativas (ancho, alto, área y relación de aspecto) diferenciadas por clase, evidenciando diferencias en la variabilidad geométrica entre *dog* y *defecating-dog* mediante estimaciones de densidad (KDE).

Técnicas de Data Augmentation

Se optó por delegar el aumento de datos primario a las capacidades nativas de transformación en línea de YOLO durante el entrenamiento (color jittering, escalado moderado). Dadas las características de perspectiva estática de las cámaras CCTV, se establece la decisión de **desactivar transformaciones destructivas del contexto espacial**, como el filtro *Mosaic*, dado que el uso de esta, alteraría gravemente la coherencia geométrica que las variables NAP e IPD buscan preservar, mezclando escalas incompatibles en un mismo frame.

Pipeline de Preprocesamiento Automatizado

La reproducibilidad del experimento se garantizó mediante la instanciación de un script interactivo basado en ipywidgets y pandas. Este flujo maestro agrupa los datos, calcula las fronteras del IQR por ID de clase, computa las variables espaciales (NAP/IPD), filtra anomalías lógicas, previsualiza los impactos en las imágenes afectadas y presenta una

top 20 y un listado de las instancias implicadas y un abstract del impacto sobre el dataset para que el humano tome la decisión de ejecutar o no el preprocesamiento de manera automatizada. Cuando el humano decide hacerlo entonces finalmente, re-empaqueta los `.txt` en la estructura de directorios canónica de YOLO (`_Cleaned_FE`), eliminando el sesgo de la intervención manual en la fase de preprocesamiento.

El mencionado preprocesamiento utiliza la técnica del IQR para darle tratamiento a los outliers identificados de una manera automatizada pero usando HITL (Human in the Loop) para asegurar una correcta toma de decisiones.

Figura 14

Pipeline interactivo de preprocesamiento automatizado con enfoque Humano

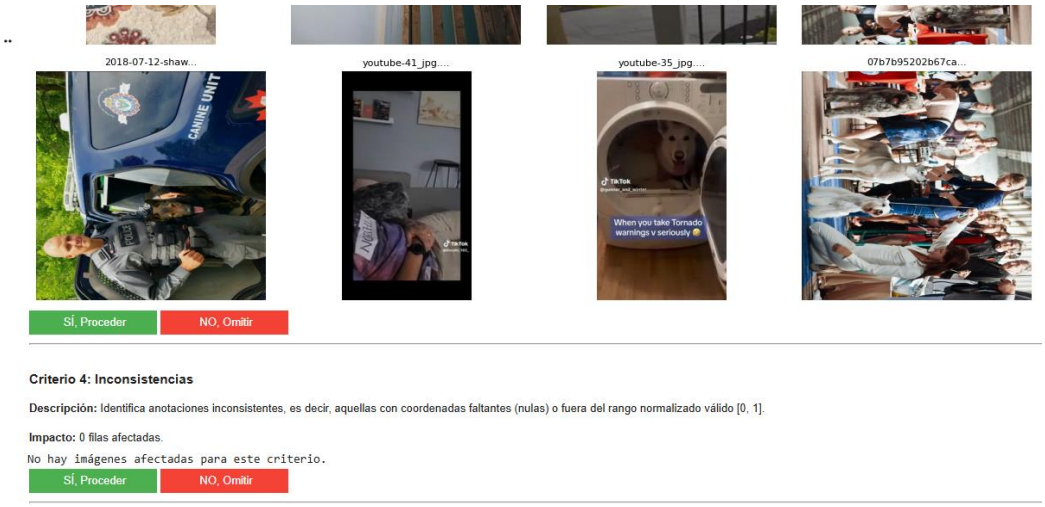

Nota. Se presenta pipeline interactivo con pandas e ipywigedts donde se presenta al humano la información necesaria para la toma de decisiones del pre procesamiento automatizado

Conclusiones

Eficacia de la Filtración Contextual: La retención estratégica de objetos de área minúscula y el uso de imágenes de *background* asegura que el modelo aprenda a ignorar el entorno de la propiedad horizontal, adaptándose a la realidad operativa del sistema CCTV donde los sujetos pueden aparecer en el plano focal lejano.

Aislamiento de Ruido mediante Feature Engineering: La creación de las variables NAP e IPD demostró ser una heurística altamente efectiva para curar datasets de

videovigilancia. Su aplicación empírica permitió discriminar y extirpar artefactos del piso (sombras/basura) que las revisiones manuales o los filtros estadísticos estándar (solo área) habrían ignorado.

Robustez Distribucional: El dataset consolidado presenta una calidad estructural óptima. La eliminación de duplicados, la corrección de inconsistencias dimensionales y el desbalance contenido de 1.21:1 proveen un escenario estadísticamente maduro que mitiga el riesgo de sesgo hacia la clase mayoritaria sin corromper la distribución real del evento (defecación vs tránsito normal).

Recomendaciones

Ajuste de Hiperparámetros (Función de Pérdida)

Si durante la validación del primer entrenamiento base (*baseline*) se observa una degradación en la métrica *Recall* de la clase minoritaria (`defecating-dog`), se recomienda habilitar explícitamente los pesos de clase (*class weights*) o transicionar hacia una *Focal Loss* para forzar a la red a priorizar los falsos negativos.

Desactivación de Aumentos Anti-Perspectiva

Configurar los hiperparámetros de entrenamiento de YOLOv11 para establecer `mosaic: 0.0` y restringir rotaciones severas (`degrees: 0.0`). Esto es vital para preservar las reglas de perspectiva geométrica (objetos lejanos = pequeños y arriba) que caracterizan de manera intrínseca a este problema de visión por computador.

Referencias

JJocher, G., Chaurasia, A., & Qiu, J. (2023). YOLO by Ultralytics (Versión 8.0.0) [Software]. GitHub. https://github.com/ultralytics/ultralytics

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788. https://doi.org/10.1109/CVPR.2016.91

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.