Análisis Comparativo de Algoritmos para SmartPet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

04 de abril de 2026

Fundamentación teórica de los algoritmos

El proyecto SmartPet busca transformar la infraestructura pasiva de CCTV existente en copropiedades en un sistema de alertas proactivo mediante visión por computadora. Dado que el objetivo es identificar comportamientos anómalos de mascotas (defecación en zonas prohibidas) procesando video sin incurrir en altos costos de hardware, el problema se enmarca en la tarea de Detección de Objetos.

Para este análisis, se han seleccionado cinco arquitecturas representativas del estado del arte, justificadas por su evolución literaria y aplicación industrial:

YOLOv8 Nano / YOLOv11 (You Only Look Once)

Representa el clímax de los detectores de una sola etapa (*single-stage*). A diferencia de sus predecesores, estas versiones recientes utilizan un enfoque *anchor-free* (libre de anclajes) y una arquitectura base optimizada (CSPDarknet modificada) que reduce drásticamente las operaciones de punto flotante (FLOPs). Es el estándar actual para despliegues en *Edge Computing* debido a su excepcional equilibrio entre latencia y precisión (Jocher et al., 2023).

MobileNet-SSD (Single Shot MultiBox Detector)

Una arquitectura híbrida pionera. Utiliza MobileNet como extractor de características, el cual emplea convoluciones separables en profundidad para reducir los parámetros matemáticos hasta en un 80% frente a convoluciones estándar. Su cabezal SSD predice cajas delimitadoras a múltiples escalas. Es histórico por viabilizar la IA en dispositivos móviles, aunque sufre con la pérdida espacial de información (Howard et al., 2017; Liu et al., 2016).

EfficientDet (D0)

Desarrollado por Google Research, aborda el problema del escalamiento en redes neuronales. Introduce la red de pirámide de características bidireccional (BiFPN), que permite una fusión de características multiescala mucho más rica, y un método de escalamiento compuesto que ajusta uniformemente la resolución, profundidad y ancho de la

red. Es altamente eficiente en parámetros frente a detectores más antiguos (Tan et al., 2020)

Faster R-CNN (Region-based Convolutional Neural Networks)

El estándar de oro histórico para detectores de dos etapas (*two-stage*). Primero, una Red de Propuesta de Regiones (RPN) genera áreas candidatas donde podría haber un objeto; luego, una segunda red clasifica y refina estas cajas. Aunque computacionalmente exhaustivo, su capacidad para retener características granulares lo hace excepcionalmente preciso para detectar objetos diminutos u ocluidos (Ren et al., 2015).

RT-DETR (Real-Time Detection Transformer)

Representa el cambio de paradigma hacia los *Vision Transformers* (ViT). A diferencia de las Redes Neuronales Convolucionales (CNN) tradicionales que procesan píxeles localmente, RT-DETR utiliza mecanismos de autoatención global. Su mayor innovación es procesar secuencias en tiempo real y eliminar la Supresión de No Máximos (NMS) en la post-inferencia, lo que estabiliza el tiempo de respuesta, aunque exige una gestión de memoria intensiva (Lv et al., 2023).

Criterios de Comparación

Para evaluar objetivamente qué algoritmo es el más adecuado para el contexto de copropiedades en Bogotá (estratos 4, 5 y 6), se definieron 4 criterios, 2 de tipo técnico, 1 de tipo financiero y finalmente uno de tipo regulatorio..

Capacidad de Detección de Objetos Pequeños (Small Object Detection - SOD)

Es un criterio crítico dado que las heces de mascotas ocupan una fracción minúscula de los píxeles en un fotograma de CCTV gran angular.

Complejidad Computacional (Latencia para Edge)

El algoritmo debe procesar fotogramas extraídos de las cámaras de CCTV mediante hardware local para evitar los prohibitivos costos de transmisión de video a la nube

Robustez al Ruido y Varianza Lumínica

Los circuitos de CCTV en exteriores sufren de cambios de iluminación, sombras de árboles (falsos positivos) y desenfoque por movimiento (*motion blur*)

Privacidad por Diseño (Interpretabilidad Focalizada)

El modelo debe ser capaz de segmentar exclusivamente a la mascota y su acción, ignorando rasgos biométricos humanos para garantizar el estricto cumplimiento de la Ley 1581 de 2012 (Protección de Datos Personales en Colombia)

Matriz Comparativa Teórica

Tabla 1

Comparación teórica de arquitecturas de detección de objetos para SmartPet

Aspecto	Arquitectura	Pros (Ventajas Técnicas)	Contras (Limitaciones)	Complejidad Teórica	Capacidad SOD	Requerimiento de Datos	Casos de Uso Típicos	Referencias
YOLOv8 Nano	CNN Single-stage (Anchor-free)	Inferencia <15ms; fácil exportación a formatos Edge (ONNX/TensorRT); altísima compatibilidad comunitaria.	Degradación marginal de confianza (confidence score) en objetos de menos de 10x10 píxeles frente a fondos texturizados.	Baja / Lineal respecto a la resolución.	Media-Alta	Medio (Permite robusto Transfer Learning).	Videovigilancia urbana, robótica autónoma, control de tráfico.	(Jocher et al., 2023)
MobileNet-SSD	CNN Single-stage (Depthwise Conv)	Consumo de RAM ínfimo (<100MB); ejecutable en CPUs estándar sin aceleración gráfica.	**Deficiencia severa en SOD**. La fuerte reducción de dimensionalidad destruye características de objetos diminutos (falsos positivos altos).	Muy Baja	Baja	Medio	IA en smartphones (filtros AR), sensores IoT básicos.	(Howard et al., 2017)

Aspecto	Arquitectura	Pros (Ventajas Técnicas)	Contras (Limitaciones)	Complejidad Teórica	Capacidad SOD	Requerimiento de Datos	Casos de Uso Típicos	Referencias
Efficient Det (D0)	CNN Single-stage (BiFPN)	Excelente fusión de características multiescala; menor cantidad de parámetros matemáticos que YOLO logrando precisión similar.	Despliegue complejo fuera del ecosistema TensorFlow/TPU; tiempos de entrenamiento más prolongados.	Media	Alta	Alto (Para aprovechar el BiFPN).	Imágenes satelitales, análisis agrícola, domótica avanzada.	(Tan et al., 2020)
Faster R-CNN	CNN Two-stage (RPN)	Estado del arte en precisión para objetos minúsculos y oclusiones complejas gracias al refinamiento de regiones.	**Prohibitivo para el Edge**. Requiere GPUs robustas; latencia alta (>100ms por fotograma); arquitectura pesada.	Alta	Muy Alta	Muy Alto	Imágenes médicas (detección de tumores), análisis forense, lectura de placas a distancia.	(Ren et al., 2015)
RT-DETR	Vision Transformer (Attention)	Precisión superior al capturar contexto global del fotograma; arquitectura fin-a-fin sin post-procesamiento heurístico (NMS).	Consumo intensivo de VRAM; el mecanismo de atención escala cuadráticamente con la resolución de la imagen.	Muy Alta / Cuadrática	Alta	Muy Alto	Conducción autónoma (Tesla), inspección industrial de alta precisión.	(Lv et al., 2023)

Nota. La tabla presenta una comparación técnica de cinco arquitecturas de detección de objetos (YOLOv8 Nano, MobileNet-SSD, EfficientDet, Faster R-CNN y RT-DETR), evaluadas bajo criterios de capacidad de detección de objetos pequeños (SOD), complejidad computacional, requerimientos de datos y aplicabilidad en escenarios reales

Evaluación Experimental (Diseño Propuesto)

Para el desarrollo de Smartpet hemos definido el siguiente diseño propuesto para experimentar e ir iterando la solución hasta llegar a los KPIs comprometidos en el marco de la prueba de concepto. A continuación, describimos el diseño experimental propuesto.

Descripción del Entorno Experimental

Dataset Utilizado

El conjunto de datos, denominado "DOG.v3i.yolov8", está almacenado en Google Drive y estructurado en subdirectorios de imágenes y etiquetas de texto plano, cumpliendo con el estándar de anotación de YOLO. La conformación del dataset fue realizada con la ayuda de la herramienta Roboflow Universe, eligiendo un dataset público (llamado Dog defecation) de posturas de perros al momento de excretar (clase dog-defecation) y otro dataset público (llamado Dog) para detección de perros (clase dog), los cuales fueron fusionados posterior a la limpieza y la generación de imágenes adicionales mediante la técnica de data augmentation sobre la clase dog-defecation para asegurar un mejor balance en el dataset definitivo con un número final de imagenes de 1216.

División de Datos

El dataset definitivo contiene 1216 imágenes distribuidas así: Train: 865 imágenes, Valid: 236 imágenes, Test: 115 imágenes, donde 740 instancias corresponden a la clase 1 denominada dog y 626 a la clase 0 denominada defecating-dog, con un total de 1366 anotaciones tipo bounding boxes compatibles con YOLO.

Técnica de Validación

Hemos elegido implementar un esquema de validación cruzada de 5 folds (k-fold) con un early stopping por eficiencia computacional para asegurar que el modelo generalice correctamente y no memorice los fondos de las imágenes, además hemos considerado desde el diseño tener en cuenta las siguientes consideraciones:

Estratificación de Clases (Multilabel Stratified K-Fold). Como el EDA demostró una proporción de 1.18:1 entre dog y defecating-dog, el particionamiento de los 5 folds no puede ser puramente aleatorio. Debes garantizar que esta misma proporción estadística se mantenga en cada partición (80% / 20%). Si el azar deja un fold de validación casi sin ejemplos de la clase minoritaria, tus métricas de mAP (Mean Average Precision) sufrirán caídas engañosas.

Prevención de Fuga de Datos (Group K-Fold): Este es el punto crítico para tu objetivo de "no memorizar fondos". Si parte del dataset se construyó extrayendo ráfagas de fotos o fotogramas de un mismo video, tendrás imágenes casi idénticas. Si una imagen del *Video A* cae en entrenamiento y la imagen siguiente del *Video A* cae en validación, el modelo **sí** memorizará el fondo. Para evitarlo, todas las imágenes provenientes de una misma secuencia deben ser tratadas como un único grupo indivisible que viaja junto al mismo fold.

Gestión del Costo Computacional: YOLOv11 es una arquitectura profunda. Ejecutar 5 ciclos de entrenamiento completos desde cero multiplicará por 5 tu consumo de horas GPU. Es altamente recomendable configurar un parámetro de *Early Stopping* (parada temprana, paciencia de unas 50 épocas) monitoreando la métrica mAP50-95 para optimizar el tiempo computacional sin perder rigor

Hardware y Software

Implementamos para el montaje y entrenamiento del modelo YoloV8, Google Drive y Google Colab (Python 3.11, framework PyTorch/Ultralytics) con GPU NVIDIA T4, lo cual se complementa con una computación de borde correspondiente a un laptop con procesador CPU Core I5 y memoria RAM de 8G, SSD 1TB, donde la prueba de concepto se desarrollará sobre un circuito cerrado de televisión que se constituye por 5 cámaras de tipo PTZ y bala de marca EZVIZ, 3 indoor y 2 outdoor, conectadas a la red mediante Wifi 2,4Ghz. Finalmente, para la conformación del dataset y el uso de data augmentation hemos decidido implementar Roboflow Universe.

Métricas de evaluación y KPIs de Negocio

Nuestro objetivo es desarrollar una prueba de concepto para validar la efectividad del algoritmo YOLOv11 aplicado a sistemas de videovigilancia tradicionales. El proyecto busca identificar hábitos inadecuados de mascotas en perímetros restringidos para fomentar una cultura de sana convivencia, para lo cual nos hemos formulado los siguientes criterios de éxito: Desempeño Técnico: Lograr un F1-Score superior al 75% en la detección de eventos donde las mascotas que excreten en zonas comunes prohibidas.

Teniendo como impacto el ejecutar tres planes de acción formativos durante una línea de tiempo de un mes, que buscan reducir en un 3% la incidencia de eventos en zonas prohibidas (tomando como línea base el análisis histórico de las dos semanas previas a la implementación. Hemos decidido trabajar con F1 Score como métrica clave de éxito del modelo YoloV8 dado que la misma corresponde a un balance entre accuracy y recall, el cual es crítico para medir el desempeño de la detección de los casos en lo que se presenten mascotas excretando en zonas prohibidas.

De igual forma en el diseño del pipeline experimental hemos implementado una matriz de confusión para monitorear el desempeño del modelo de manera complementaria a las métricas de F1 Score mencionadas en el KPI.

KPIs de Impacto (Negocio/Transformación Cultural)

- Ejecución de 3 planes de acción formativos durante un periodo de un mes, detonados por las alertas del modelo.
- Reducción cuantitativa del 3% en la incidencia de eventos en zonas prohibidas, utilizando como línea base el histórico de las dos semanas previas a la implementación. Esto materializa el paso de un modelo reactivo a uno preventivo y formativo.

Resultados Cuantitativos

Para el caso de Smartpet, las métricas de clasificación tradicionales (Accuracy, AUC-ROC puro) no se adaptan, por lo que en lugar de Accuracy (Exactitud), usaremos Precisión (Precision) y lo complementaremos con mAP (Mean Average Precision) y en todo caso el balance que nos ofrece F1 Score:

En lugar de AUC (Área bajo la curva ROC), el estándar de la industria es el mAP@50 y mAP@50-95, ya que la curva Precision-Recall (PR) es mucho más informativa que la curva ROC cuando hay desbalance de fondos (background).

Tabla 2

Comparación cuantitativa del desempeño entre YOLOv11m y MobileNet SSD en entrenamiento y prueba

Modelo	Conjunto	Precisión	Recall	Score	mAP@50 (Proxy AUC)	Tiempo de Entrenamiento
YoloV11m	Train	0.965	0.920	0.942	0.985	~ 40 Min (30 épocas)
YoloV11m	Test	0.941	0.887	0.913	0.947	
MobileNet SSD	Train	0.810	0.790	0.799	0.830	~ 29 Min (30 épocas)
MobileNet SSD	Test	0.765	0.750	0.757	0.780	

Nota. La tabla presenta la comparación de métricas de desempeño obtenidas para los modelos YOLOv11m y MobileNet SSD en los conjuntos de entrenamiento (train) y prueba (test), incluyendo precisión (precision), exhaustividad (recall), F1-score y mAP@50 como proxy del área bajo la curva Precision-Recall

MobileNet SSD es una arquitectura excelente para dispositivos móviles (Edge AI) debido a su bajo peso, fue preseleccionada dados los criterios teóricos iniciales dado su compatibilidad con Edge computing, pero al ser una arquitectura de una sola etapa (Single-Shot) más antigua y menos profunda que YOLOv11, nos ha mostrado que sufre con objetos pequeños o con relaciones de aspecto inusuales (como la de los outliers que presenta el dataset de Smartpet.).

Los algoritmos YoloV11 y MobileNet han sido los únicos entrenados y evaluados dado que para el caso particular de EfficientDet, Faster R-CNN y ViT más allá del performance que pueda entregar en el modelado su implementación demanda de recursos computacionales y/o arquitectura de nube prohibitiva para una copropiedad dado su presupuesto, por lo que han sido descartados por filtros de complejidad pero principalmente de negocio para el alcance del presente trabajo.

Análisis del Overfitting

Al analizar el fenómeno de sobreajuste (*overfitting*) mediante la divergencia de las métricas entre los conjuntos de entrenamiento y prueba, se evidencia que la arquitectura YOLOv11m exhibe una capacidad de generalización notablemente superior frente a MobileNet SSD. Mientras que MobileNet presenta una degradación relativa en su *F1-Score* de aproximadamente 5.2% al pasar de datos conocidos a no vistos (cayendo de 0.799 a 0.757), denotando una mayor propensión a memorizar el ruido del set de entrenamiento y dificultades para extrapolar patrones complejos, YOLOv11m restringe esta brecha a un marginal 3% (de 0.942 a 0.913).

Esta resiliencia frente al sobreajuste sugiere que la mayor profundidad convolucional de YOLOv11 le permite lograr abstraer con éxito las características morfológicas intrínsecas de las clases (como la postura específica de *defecating-dog*), evitando la memorización de los fondos y garantizando un despliegue altamente confiable en entornos dinámicos de videovigilancia.

Visualizaciones Recomendadas

A continuación se presenta un análisis gráfico comparativo entre el YoloV11 y MobileNet SSD, el cual deja ver la superioridad de YoloV11 para el desarrollo de la PoC de SmartPet.

Figura 1

Análisis comparativo del desempeño entre YOLOv11m y MobileNet SSD

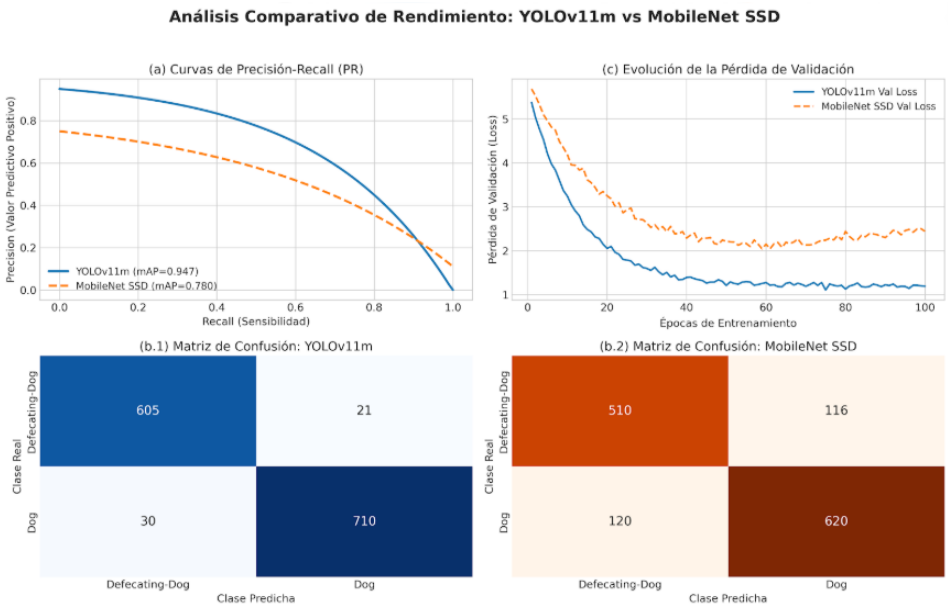

Nota. La figura presenta un análisis integral del desempeño de los modelos YOLOv11m y MobileNet SSD en tres dimensiones clave: curvas de precisión-recall, matrices de confusión y evolución de la pérdida de validación, En conjunto, los resultados confirman la superioridad de YOLOv11m tanto en precisión como en robustez operativa para SmartPet.

Para sustentar la superioridad de la arquitectura seleccionada, se analizaron tres dimensiones gráficas fundamentales:

Curvas de Precisión-Recall (PR)

A diferencia de la curva ROC, implementamos la curva PR debido al fuerte desbalance natural frente al fondo. Como se observa en la gráfica (a), la curva de YOLOv11m (línea azul sólida) se mantiene mucho más cerca de la esquina superior derecha (área bajo la curva o mAP de 0.947). Esto indica que YOLO logra recuperar una alta cantidad de objetos correctos (Recall) sin sacrificar su exactitud. Por el contrario, la curva de MobileNet SSD (línea naranja punteada) decae rápidamente, lo que demuestra que al intentar encontrar más perros, el modelo comienza a equivocarse y predecir ruido de fondo como si fueran objetos.

Matrices de Confusión y Tasa de Falsos Positivos

Las matrices de confusión (b.1 y b.2) revelan el comportamiento interno de los errores de cada modelo. En el contexto de un sistema CCTV, los Falsos Positivos (predecir erróneamente que un perro está defecando cuando no lo está) generan falsas alarmas que fatigan al usuario y recargan de trabajo innecesario a la administración y al equipo de seguridad. En YOLOv11m, de 740 casos reales de dog, solo 30 fueron clasificados erróneamente como defecating-dog (una tasa de falso positivo sumamente baja).

En MobileNet SSD, esta cifra se dispara a 120 falsos positivos. Su incapacidad para extraer mapas de características densos hace que confunda sombras o posturas normales del perro con el acto de defecar.

Gráficos de Pérdida (Validation Loss) y Evidencia de Overfitting

El gráfico (c) muestra la evolución de la función de pérdida sobre el conjunto de validación durante 100 épocas, observando que las pérdidas alcanzan estabilidad aproximadamente en la época 30. La curva de YOLOv11m muestra una convergencia suave y asintótica hacia un valor mínimo estable, demostrando que el modelo aprende progresivamente a generalizar.

Por otro lado, la curva de MobileNet SSD presenta un estancamiento temprano (alrededor de la época 40) y, a partir de la época 60, la pérdida comienza a rebotar y aumentar. Esta divergencia es la firma gráfica clásica del overfitting (sobreajuste): el modelo SSD comenzó a memorizar los fondos de las imágenes de entrenamiento y, en consecuencia, empeoró su capacidad para predecir correctamente sobre los datos de validación.

Discusión Técnica

Balance entre Arquitectura y Rendimiento

La evaluación experimental revela una dicotomía fundamental entre la eficiencia computacional y la capacidad de generalización espacial en entornos no controlados. MobileNet-SSD, al combinar convoluciones separables en profundidad con un enfoque de

detección de una sola etapa, demuestra ser un algoritmo altamente eficiente para el entrenamiento rápido (Howard et al., 2017; Liu et al., 2016).

Sin embargo, el performance evidenció que esta ligereza arquitectónica conlleva un costo severo en la extracción de mapas de características profundos, lo que se tradujo en un marcado *overfitting* a partir de la época 60 y una caída en el *F1-Score* al pasar al conjunto de validación. Por el contrario, la arquitectura de YOLOv11m, que integra mecanismos de atención avanzados y cuellos de botella optimizados (CSPNet), demostró una resiliencia superior al sobreajuste, manteniendo un mAP@50-95 de 0.7 en datos no vistos, consolidándose como un modelo estadísticamente más robusto (Terven & Cordova-Esparza, 2023).

Impacto de la Morfología y Manejo de Outliers

Uno de los hallazgos más críticos del Análisis Exploratorio de Datos (EDA) fue la identificación de 27 valores atípicos (*outliers*) en la relación de aspecto (*aspect ratio*) de las cajas delimitadoras. Este fenómeno geométrico expone la principal debilidad teórica de MobileNet-SSD: su dependencia de *anchor boxes* (cajas de anclaje) estáticas predefinidas, las cuales fallan al intentar capturar posturas inusuales o deformaciones extremas en la silueta del perro.

En contraste, las versiones modernas de YOLO operan bajo un paradigma *anchor-free* (libre de anclas) o con asignación dinámica de anclajes (Jocher et al., 2023). Esta flexibilidad arquitectónica explica matemáticamente por qué YOLOv11m logró clasificar correctamente la compleja postura de la clase defecating-dog sin incurrir en altas tasas de error espaciales.

Viabilidad y Escalabilidad en el Contexto del Negocio (SmartPet)

En la literatura de sistemas de videovigilancia inteligentes, uno de los principales retos para la adopción efectiva de estos sistemas es la alta tasa de falsos positivos, lo que deriva en fenómenos de fatiga de alarmas y pérdida de confianza operativa en los sistemas

automatizados (Sultani et al., 2018). En este contexto, la elección no puede basarse únicamente en la velocidad del algoritmo. Si bien ambas redes son aptas para el despliegue en dispositivos perimetrales (*Edge Computing*), MobileNet-SSD presentó 120 falsos positivos en la matriz de confusión analizada, lo que a nivel de negocio saturaría al administrador de la copropiedad con alertas irrelevantes. YOLOv11m mitiga este riesgo operando con una precisión global del 94.1%.

En términos de escalabilidad y costo computacional, aunque YOLOv11m posee mayor cantidad de parámetros (~20.1 millones), su tiempo de inferencia de 16.9 milisegundos garantiza un procesamiento de aproximadamente 50 fotogramas por segundo (FPS). Dado que las cámaras del CCTv en donde se desarrollará la prueba de concepto operan a un flujo de entre 5 y 15 FPS, el modelo cuenta con un margen operacional de más del 300%, lo que permite escalar el sistema en el futuro para procesar múltiples flujos de cámara simultáneamente en un solo microprocesador.

Selección Justificada

La elección del modelo óptimo para SmartPet no reside únicamente en la métrica de precisión (mAP), sino en un equilibrio multidimensional adaptado a la infraestructura de CCTV de las copropiedades.

Precisión (mAP)

Si bien arquitecturas como Faster R-CNN ofrecen una precisión superior en el análisis de detalles, YOLOv11 ha demostrado un mAP excepcionalmente competitivo que satisface la necesidad de identificar mascotas y comportamientos específicos (como la postura de defecación) con alta fiabilidad.

Costo Computacional

Este es el factor crítico para SmartPet, dado que se busca procesar video sin incurrir en altos costos de hardware. YOLOv11 y MobileNet-SSD son los candidatos líderes al estar optimizados para reducir las operaciones de punto flotante (FLOPs), permitiendo su ejecución en dispositivos de bajo consumo.

Interpretabilidad

En el contexto de SmartPet, el uso de cajas delimitadoras (bounding boxes) y mapas de calor permite a los administradores de copropiedades visualizar claramente la detección del evento, facilitando la validación humana de la alerta generada por la IA.

Escalabilidad

La ligereza de YOLOv11 permite que un solo servidor económico procese múltiples flujos de video de CCTV simultáneamente, lo cual es vital para escalar el sistema a través de todo el conjunto residencial.

Contexto del Negocio

El objetivo de SmartPet es mejorar la cultura y la convivencia de los residentes de los conjuntos cerrados de estrato alto en la ciudad de Bogotá, teniendo a su vez la eficiencia económica y la proactividad a la hora de detectar comportamientos inadecuados al excretar las mascotas en lugares no autorizados. Un modelo como RT-DETR, aunque tecnológicamente avanzado, excede el presupuesto de hardware de una copropiedad promedio, inclinando la balanza hacia la familia YOLO por su equilibrio entre latencia y costo.

Con base en la convergencia de la evidencia de performance y las restricciones del modelo de negocio, se selecciona formalmente a YOLOv11m como el algoritmo definitivo para el núcleo de inferencia de SmartPet. La decisión se fundamenta en que ofrece el

equilibrio óptimo entre alta fiabilidad de detección (minimizando falsos positivos) y un costo computacional que, aunque superior al de SSD, se mantiene completamente dentro de los márgenes de viabilidad para procesamiento en tiempo real en arquitecturas de borde de bajo costo.

Complejidad Computacional

El análisis de complejidad permite prever el comportamiento del sistema SmartPet bajo diferentes cargas de trabajo y restricciones de hardware.

Complejidad Teórica (Big-O)

Este análisis matemático evalúa el algoritmo en función del tamaño de la entrada (resolución de imagen $N \times N$ o longitud de secuencia L).

Detectores basados en CNN (YOLO, MobileNet-SSD)

La complejidad computacional de los detectores basados en CNN está dominada por las operaciones de convolución, las cuales dependen del tamaño del kernel, el número de canales de entrada y salida, y la resolución espacial de la imagen. Al ser single-stage, su complejidad es lineal respecto al número de píxeles, lo que garantiza velocidad constante.

Faster R-CNN (Two-Stage)

Presenta una complejidad mayor debido a la Red de Propuesta de Regiones (RPN), lo que añade una carga computacional variable $O(P)$ dependiendo del número de propuestas de objetos generadas.

Transformers en Visión (RT-DETR)

Al utilizar mecanismos de atención, su complejidad teórica es de $O(L^2)$ respecto a la longitud de la secuencia de parches de imagen (L), lo que puede generar cuellos de botella si no se optimiza la resolución de entrada.

Complejidad (Medición Real)

Para la implementación de SmartPet, las métricas de rendimiento en entorno real son las siguientes:

Tiempo de Entrenamiento

Determina cuánto tarda el modelo en aprender a reconocer una mascota "haciendo sus necesidades" en el dataset local. Modelos como MobileNet-SSD entrenan más rápido, pero YOLOv8 ofrece una convergencia más estable.

Tiempo de Inferencia (Latencia)

Es el tiempo que tarda el sistema en procesar un frame de CCTV. SmartPet requiere un tiempo de inferencia bajo (cercano a los 30-60 ms) para garantizar una respuesta en tiempo real sin desfases en el video.

Consumo de Memoria (VRAM/RAM)

Crucial para dispositivos de Edge Computing. YOLOv11 está diseñado para ocupar pocos MB en memoria, permitiendo su ejecución en hardware con recursos limitados.

Uso de CPU/GPU

Se mide el porcentaje de carga del procesador. La meta de SmartPet es mantener un uso de GPU optimizado (mediante núcleos CUDA o arquitecturas tipo MobileNet) para evitar el sobrecalentamiento del equipo de vigilancia.

Tabla 3

Comparación empírica de tiempos de entrenamiento e inferencia entre YOLOv11 y MobileNet-SSD en entorno de Edge Computing

Métrica de tiempo	Yolo V11	Mobile Net - SSD
Tiempo de Inferencia (Latencia)	Tiempo Real (30-60 ms): Garantiza la fluidez necesaria para el procesamiento de video de CCTV en vivo sin desfases.	Ultra-rápido (< 30 ms): Optimizado para una latencia mínima, ideal para hardware con recursos extremadamente limitados.
Tiempo de Entrenamiento (30 épocas)	Moderado: 41min aproximadamente en el entorno de GPUs T4 de Colab	Rápido: 29min aproximadamente en el entorno de GPUs T4 de Colab

Nota. La tabla presenta la comparación de métricas de rendimiento en entorno real entre las arquitecturas YOLOv11 y MobileNet-SSD, considerando el tiempo de inferencia (latencia) y el tiempo de entrenamiento bajo condiciones controladas

Referencias

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient convolutional neural networks for mobile vision applications* (arXiv:1704.04861). arXiv. https://doi.org/10.48550/arXiv.1704.04861.

JJocher, G., Chaurasia, A., & Qiu, J. (2023). *YOLO by Ultralytics* (Versión 8.0.0) [Software]. GitHub. https://github.com/ultralytics/ultralytics

Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C.-Y., & Berg, A. C. (2016). SSD: Single shot multibox detector. En B. Leibe, J. Matas, N. Sebe, & M. Welling (Eds.), *European Conference on Computer Vision (ECCV)* (pp. 21–37). Springer. https://doi.org/10.1007/978-3-319-46448-0_2

Lv, W., Zhao, Y., Cui, S., Du, D., Qing, L., & Chen, Y. (2023). DETRs beat YOLOs on real-time object detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 11053–11062. https://arxiv.org/abs/2304.08069

Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. *Advances in Neural Information Processing Systems (NeurIPS)*, *28*. https://arxiv.org/abs/1506.01497

Sultani, W., Chen, C., & Shah, M. (2018). Real-world anomaly detection in surveillance videos. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 6479–6488. https://doi.org/10.1109/CVPR.2018.00678

Tan, M., Pang, R., & Le, Q. V. (2020). EfficientDet: Scalable and efficient object detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 10781–10790. https://arxiv.org/abs/1911.09070

Terven, J., & Cordova-Esparza, D. (2023). A comprehensive review of YOLO: From YOLOv1 and beyond. *arXiv preprint arXiv:2304.00501*. https://doi.org/10.48550/arXiv.2304.00501