Recursos y Estado del Arte Proyecto SmartPet: Diseño, Evaluación y Optimización del Sistema

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

08 de mayo de 2026

Resumen

El presente informe detalla de manera exhaustiva el ciclo de vida, desarrollo, evaluación y optimización del proyecto SmartPet, un sistema avanzado de inteligencia artificial fundamentado en la arquitectura convolucional YOLOv11m. Este desarrollo tecnológico está diseñado para la detección automatizada y en tiempo real de comportamientos anómalos caninos, específicamente la excreción en zonas residenciales prohibidas, procesando flujos de video de Circuitos Cerrados de Televisión (CCTV) bajo el paradigma de computación en el borde (Edge AI). La investigación aborda la problemática desde una perspectiva interdisciplinaria que amalgama el rigor técnico de la visión por computadora con los imperativos legales de protección de datos personales establecidos en la legislación colombiana. A través de una narrativa cronológica basada en entregas parciales, el documento muestra la transición metodológica desde el análisis comparativo del estado del arte hasta la optimización determinista de hiperparámetros mediante técnicas de interpretabilidad de caja negra, como los Gráficos de Dependencia Parcial (PDP). El análisis empírico demuestra que la arquitectura YOLOv11m supera de manera contundente a líneas base históricas como MobileNet-SSD, alcanzando un F1-Score del 91.3% y manteniendo una latencia perimetral de 16.9 milisegundos, viabilizando su implementación a gran escala sin depender de costosas infraestructuras en la nube. Asimismo, el estudio profundiza en la equidad algorítmica, revelando que el sesgo en videovigilancia no controlada es de naturaleza morfológica y espacial, requiriendo intervenciones estructurales como la Inferencia Hiper-Fragmentada Asistida (SAHI) para mitigar las deficiencias en la detección de objetos pequeños. El sistema es sometido a un riguroso taller de simulación de escenarios críticos, comprobando su resiliencia frente a ruido, pérdida de datos y deriva de la distribución (drift). Finalmente, el documento propone un cronograma de implementación bajo metodología ágil, estructurado en ocho Sprint para un conjunto residencial de estrato 6 en Bogotá, garantizando el cumplimiento irrestricto de la Ley 1581 de 2012 y la Circular Externa 002 de 2024 de la Superintendencia de Industria y Comercio.

Introducción

La densificación demográfica, la acelerada urbanización y la verticalización de los espacios de vivienda han transformado profundamente las dinámicas de convivencia dentro de los regímenes de propiedad horizontal, particularmente en urbes como la ciudad de Bogotá (Congreso de Colombia, 2001). En estos ecosistemas residenciales, la tenencia de animales de compañía ha experimentado un crecimiento sostenido, consolidándose como un factor determinante en el bienestar emocional de los núcleos familiares contemporáneos. Sin embargo, esta misma dinámica se ha erigido paralelamente como una de las fuentes primarias de conflictos vecinales, derivados de manera fundamental del manejo inadecuado de los residuos biológicos en áreas comunes, senderos peatonales y zonas verdes protegidas. Históricamente, la mitigación de estas contravenciones a los manuales de convivencia ha dependido casi en su totalidad de la vigilancia humana presencial y de la revisión manual retrospectiva de los circuitos cerrados de televisión (CCTV) por parte del personal de seguridad de las administraciones residenciales. Estos métodos tradicionales resultan crónicamente ineficientes, son altamente propensos a la fatiga visual humana, y se tornan financieramente insostenibles frente a los incrementos exponenciales en las tarifas reguladas de seguridad privada (Copropiedades, 2026).

Ante esta problemática estructural que afecta la calidad de vida comunitaria, la visión por computadora y, en particular, las redes neuronales convolucionales (CNN) de una sola etapa, ofrecen un paradigma disruptivo y proactivo para la detección de anomalías en tiempo real. El proyecto SmartPet se articula como una respuesta tecnológica integral orientada a transformar la infraestructura pasiva de videovigilancia en un ecosistema de monitoreo inteligente, predictivo y preventivo (Jocher et al., 2023). No obstante, la transposición de modelos teóricos de aprendizaje profundo a infraestructuras de vigilancia perimetral en el mundo real enfrenta barreras computacionales, geométricas y topológicas de extrema severidad. Las cámaras de seguridad suelen instalarse en posiciones elevadas para maximizar el campo de visión, lo que genera inevitablemente perspectivas de ángulo picado o negativo. Esta inclinación distorsiona de manera significativa la

escala relativa, la relación de aspecto bidimensional y la morfología aparente de los sujetos en el plano focal, alterando la firma visual de los caninos en función de su distancia al lente. Este fenómeno físico inscribe el desafío analítico directamente en el dominio de la Detección de Objetos Pequeños, un subcampo caracterizado por la escasez crítica de píxeles informativos, la alta varianza lumínica urbana y las oclusiones ambientales (Tian et al., 2025; Nikouei et al., 2025).

El presente documento desarrolla un escrutinio académico exhaustivo de las fases de diseño, curación, evaluación y puesta en marcha del proyecto SmartPet, hilando cronológicamente las entregas parciales sustentadas a lo largo de la investigación. En primer lugar, se expone la fundamentación teórica mediante un estado del arte riguroso que identifica las brechas tecnológicas en el ecosistema actual de visión artificial. Posteriormente, se aborda el análisis comparativo de algoritmos que fundamenta la elección de la arquitectura YOLOv11m, seguido de la documentación del proceso de preparación y procesamiento de datos mediante ingeniería de características avanzadas.

A continuación, el documento detalla los resultados de la evaluación del modelo frente a una línea base histórica y explora la optimización de hiperparámetros apoyada en la explicabilidad de la inteligencia artificial. Se analiza con suma profundidad la robustez del sistema frente a escenarios críticos simulados y la degradación por deriva de datos. Para concluir, se consolida la estructura de un cronograma ágil para el despliegue del sistema en un entorno de estrato 6 en Bogotá, alineando la arquitectura tecnológica con la estricta regulación de privacidad por diseño mandatada por la Superintendencia de Industria y Comercio (Superintendencia de Industria y Comercio, 2024). El propósito es demostrar la viabilidad de un modelo de inteligencia artificial que, operando desde la periferia computacional, logra transformar una fricción social en una oportunidad pedagógica, resguardando invariablemente el derecho al debido proceso y a la intimidad ciudadana.

Recursos y Estado del Arte

La construcción de una herramienta de inteligencia artificial destinada a intervenir en espacios residenciales semi públicos exige un cimiento metodológico fundamentado en la literatura científica más reciente. El estado del arte no solo proporciona un inventario de tecnologías disponibles, sino que sirve como instrumento crítico para identificar enfoques dominantes, comparar arquitecturas de redes neuronales, detectar vacíos en la aplicación industrial y sustentar de manera irrefutable el aporte original del proyecto SmartPet frente al conocimiento previamente establecido.

Estrategia de Búsqueda y Criterios de Selección

Para garantizar la actualidad, calidad y pertinencia temática de la revisión bibliográfica, se diseñó una estrategia de búsqueda sistemática anclada en bases de datos de alto impacto académico, tales como IEEE Xplore, Scopus, Web of Science y arXiv, focalizando la recolección en el periodo comprendido entre 2022 y 2026. La búsqueda se estructuró en torno a una matriz de ecuaciones booleanas diseñadas para capturar la intersección exacta entre la visión por computadora en el borde, la detección de objetos pequeños y los marcos de gobernanza de privacidad en América Latina. La ecuación principal ejecutada fue la siguiente: ("computer vision" OR "deep learning" OR "object detection") AND ("small object detection" OR "SOD" OR "Slicing Aided Hyper Inference") AND ("edge computing" OR "edge AI" OR "CCTV surveillance") AND ("privacy by design" OR "algorithmic fairness" OR "Habeas Data").

La depuración del corpus documental se sometió a estrictos criterios de inclusión y exclusión para mantener el rigor académico. Como criterios de inclusión, se admitieron exclusivamente artículos científicos revisados por pares, actas de conferencias de primer cuartil y revisiones sistemáticas recientes publicadas en los últimos cinco años. Temáticamente, se exigió que las investigaciones abordaran la detección de anomalías en entornos no controlados, el despliegue en arquitecturas de bajo consumo (Edge AI) o la gestión de sesgos espaciales.

Como criterios de exclusión, se descartaron categóricamente aquellas investigaciones enfocadas en el uso de aprendizaje automático para dominios inconexos (como diagnóstico médico o predicción financiera), estudios empíricos carentes de métricas de inferencia temporal, ensayos puramente teóricos sobre la ética de la inteligencia artificial sin implementación práctica, y publicaciones no científicas como blogs o notas de prensa.

A partir de esta rigurosa filtración, se extrajeron las variables principales, los enfoques metodológicos y los hallazgos críticos de la literatura contemporánea, lo cual permitió la construcción analítica del siguiente Mapa del Estado del Arte. Este mapa sintetiza las corrientes tecnológicas actuales y evidencia la brecha que justifica la propuesta de valor del proyecto SmartPet.

Tabla 1

Mapa del Estado del Arte en detección de objetos pequeños y visión por computadora aplicada a entornos de videovigilancia.

Autor y Año	País	Enfoque	Variable Principal	Metodología	Hallazgos	Brecha Identificada
Nikouei et al. (2025)	Global	Revisión sistemática de Detección de Objetos Pequeños (SOD)	mAP en objetos fraccionarios y métricas de escala	Análisis comparativo de extracción multiescala y mecanismos de atención en entornos UAV y CCTV	El bajo recuento de píxeles, la interferencia del fondo estático, la oclusión y el desbalance de clases son los mayores causantes de degradación predictiva en detectores estándar.	Carencia de estrategias de fusión de características que sean viables en tiempo real para entornos de hardware de borde (Edge AI) con recursos restringidos.
Jocher et al. (2023-2025); Ultralytics (2026)	EE.UU.	Arquitecturas convolucionales libres de anclajes	Precisión vs. Latencia de inferencia	Implementación de YOLOv11 con redes de agregación eficiente y cuellos de botella CSPDarknet	YOLOv11 logra una eficiencia computacional excepcional, superando a versiones previas en F1-Score utilizando un 22% menos de	Falta de especialización nativa de la arquitectura genérica para resolver distorsiones severas de ángulo picado en infraestructuras

					parámetros matemáticos.	de vigilancia urbana.
Akyon et al. (2022); Sun et al. (2025)	Turquía / China	Inferencia hiper-fragmentada para topologías masivas	Tasa de Verdaderos Positivos en objetos distantes	Slicing Aided Hyper Inference (SAHI) acoplado a detectores de una etapa	El seccionamiento de imágenes de alta resolución previo al tensor de inferencia recupera de manera drástica los objetos diminutos que el *pooling* espacial habría destruido	Alta carga computacional adicional que genera redundancia si no se implementan mecanismos adaptativos para enfocar el análisis en regiones de interés.
Tian et al. (2025); Lv et al. (2023)	China	Detectores centrados en atención global (YOLO12/26 y RT-DETR)	Eficiencia algorítmica sin Supresión de No Máximos (NMS-free)	Transformadores de Visión (ViT)	La eliminación del algoritmo NMS estabiliza los tiempos de respuesta y acelera la inferencia en CPUs hasta en un 43% frente a modelos heurísticos.	El consumo de memoria VRAM escala cuadráticamente en arquitecturas ViT, haciéndolas financieramente prohibitivas para nodos perimetrales residenciales.
Superintendencia de Industria y Comercio (2024)	Colombia	Gobernanza de privacidad y tratamiento de datos en IA	Riesgo de tratamiento de información sensible	Análisis normativo y emisión de directrices regulatorias (Circular Externa 002)	Exigencia ineludible de evaluaciones de impacto de privacidad, mitigación proactiva de sesgos algorítmicos e implementación de privacidad diferencial.	Ausencia de manuales técnicos estandarizados que enseñen cómo traducir estos imperativos jurídicos abstractos en conductos de MLOps y código fuente concreto.

Nota: La tabla sintetiza estudios relevantes en detección de objetos pequeños (SOD), arquitecturas de visión artificial y marcos regulatorios, incluyendo variables analizadas, metodologías empleadas, principales hallazgos y brechas identificadas. Se evidencia la limitación de los modelos actuales para operar en entornos de Edge AI con restricciones computacionales, así como la ausencia de integración entre equidad algorítmica y normativas de privacidad en contextos residenciales.

El análisis de este mapa revela una postura crítica innegable: si bien la academia ha logrado avances formidables en la arquitectura de redes neuronales, existe un abismo sustancial cuando se intenta trasladar estos logros a escenarios de videovigilancia residencial de bajo presupuesto. La brecha científica y técnica identificada demuestra que los modelos altamente precisos para detectar objetos pequeños (como los Transformadores de Visión) requieren clústeres de computación inalcanzables, mientras que los modelos ligeros (como MobileNet-SSD) fracasan catastróficamente al intentar discernir anomalías biológicas a gran distancia. Adicionalmente, la literatura exhibe un vacío en la intersección entre la equidad algorítmica (Fairness) focalizada en la morfología animal y los estrictos marcos regulatorios del Habeas Data colombiano. El proyecto SmartPet interviene directamente sobre esta brecha al consolidar un ecosistema que amalgama la eficiencia de YOLOv11m, la ingeniería de características espaciales para eludir la distorsión del CCTV y una arquitectura de borde que garantiza la privacidad desde el diseño al impedir la exfiltración de los flujos de video.

Fase 1: Análisis Comparativo de Algoritmos

La primera etapa operativa de la investigación consistió en establecer el núcleo algorítmico del sistema. En el dominio de la videovigilancia aplicada, la selección del algoritmo de inferencia no es un mero ejercicio estadístico, sino una decisión arquitectónica crítica que define la viabilidad financiera y técnica de toda la operación. La meta del proyecto SmartPet es transformar la infraestructura pasiva de los conjuntos residenciales en un sistema proactivo sin incurrir en costos de hardware prohibitivos, lo que sitúa la investigación en el campo de la computación en el borde.

Para determinar la viabilidad de este paradigma, se ejecutó un contraste financiero y técnico frente a los monopolios de Inteligencia Artificial como Servicio (AIaaS) basados en la nube. Las evaluaciones comerciales determinaron que la transferencia ininterrumpida de video de alta definición (streaming 24/7) hacia servidores externos genera costos depredadores que destruyen la economía del proyecto. Por ejemplo, operar una única cámara mediante plataformas como AWS

Rekognition impone un costo aproximado de $4.00 USD por hora, traduciéndose en una cifra inviable para las administraciones de propiedad horizontal. De manera análoga, ecosistemas como Google Cloud Vertex AI Vision resultan financieramente insostenibles para el monitoreo perpetuo de múltiples flujos RTSP (Google Cloud, 2026). Frente a este escenario, la inversión de capital inicial (CapEx) en microprocesadores perimetrales de bajo consumo (tales como la familia NVIDIA Jetson Orin Nano) amortiza la solución, reduciendo el costo marginal de la inferencia a niveles puramente energéticos (7W - 15W)

Confirmada la necesidad del procesamiento local, se estructuró un análisis comparativo profundo entre cinco arquitecturas representativas del estado del arte, evaluadas bajo cuatro criterios inquebrantables: capacidad de Detección de Objetos Pequeños (SOD), complejidad computacional teórica, robustez frente a la varianza ambiental (ruido e iluminación) y la interpretabilidad para garantizar la privacidad por diseño.

MobileNet-SSD (Single Shot MultiBox Detector)

Esta arquitectura pionera utiliza convoluciones separables en profundidad para comprimir la red, reduciendo los parámetros matemáticos hasta en un 80% en comparación con convoluciones estándar (Howard et al., 2017). A pesar de su consumo ínfimo de memoria RAM (inferior a 100MB), la evaluación demostró una deficiencia severa y estructural frente al criterio SOD. La agresiva reducción de dimensionalidad espacial empleada para ahorrar cómputo destruye irremisiblemente las características sutiles de la firma visual canina. Más aún, su dependencia de un conjunto estático de cajas de anclaje (anchor boxes) fracasa al intentar modelar las posturas biomecánicas inusuales generadas por los ángulos picados de las cámaras, desencadenando una inaceptable tasa de falsos positivos.

Faster R-CNN

El estándar de oro histórico para detectores de dos etapas. Emplea una Red de Propuesta de Regiones (RPN) antes de la clasificación final (Ren et al., 2015). Aunque posee una capacidad

insuperable para discriminar objetos diminutos y manejar oclusiones complejas, su complejidad computacional genera latencias de inferencia que superan los 100 milisegundos por fotograma en dispositivos de borde. Esta pesada arquitectura hace inviable la multiplexación de varias cámaras en un único procesador perimetral, descartándola para el alcance del proyecto.

EfficientDet (D0)

Desarrollada para abordar el problema del escalamiento, introduce la red de pirámide de características bidireccional (BiFPN), logrando una fusión multiescala excepcionalmente rica con un menor número de parámetros (Tan et al., 2020). Sin embargo, su despliegue resulta complejo fuera de los ecosistemas puros de TensorFlow/TPU, y exige tiempos de entrenamiento prolongados que restan agilidad a las iteraciones del proyecto.

RT-DETR (Real-Time Detection Transformer)

Representando la vanguardia tecnológica, esta arquitectura sustituye las convoluciones locales por mecanismos de autoatención global típicos de los Transformadores de Visión (ViT), eliminando el algoritmo heurístico de Supresión de No Máximos (NMS) en el post-procesamiento (Lv et al., 2023). Si bien teóricamente superior para comprender contextos urbanos holísticos, el mecanismo de atención posee una complejidad que escala cuadráticamente $O(L^2)$ respecto a la longitud de los parches de entrada. Este consumo masivo e intensivo de memoria de video (VRAM) resulta prohibitivo para el presupuesto de hardware de las copropiedades colombianas.

YOLOv11m (You Only Look Once)

La iteración contemporánea de la familia YOLO introduce un enfoque arquitectónico libre de anclajes, lo que confiere al tensor una asombrosa agilidad para asignar predicciones basándose dinámicamente en el centro semántico del objeto (Jocher et al., 2023). La integración de bloques residuales avanzados C3K2 y módulos de atención espacial transversal (C2PSA) en su espina dorsal permite optimizar el flujo del gradiente mientras se preservan características a múltiples escalas.

Posee una complejidad lineal respecto a la resolución, lo que garantiza una velocidad constante y un equilibrio perfecto entre latencia y capacidad analítica.

Con base en la convergencia de la evidencia técnica y las severas restricciones del modelo de negocio, se dictaminó de manera concluyente la selección de la arquitectura YOLOv11m. Este modelo demostró la viabilidad de operar con inferencias teóricas inferiores a 17 milisegundos, proveyendo un margen operacional del 300% frente a la tasa de fotogramas (5 a 15 FPS) característica de un CCTV residencial, lo cual facilita la consolidación de múltiples flujos en un microprocesador económico sin claudicar en la precisión de la detección.

Fase 2: Preparación y Procesamiento de Datos

La eficacia predictiva de cualquier modelo de aprendizaje profundo se encuentra inexorablemente subordinada a la calidad de la señal de supervisión proporcionada durante su entrenamiento. La fase de curación de datos para SmartPet enfrentó formidables desafíos ambientales. Dada la arquitectura inalterable de los edificios residenciales, las cámaras de videovigilancia operan con ángulos en picado (cenitales) pronunciados. Esta geometría de captura comprime la anatomía vertical de los caninos y oculta la flexión angular de los miembros posteriores, rasgo cinemático indispensable para discernir entre un estado de tránsito normal y un evento de deposición de heces.

El corpus de experimentación, denominado "DOG.v3i.yolov8", se constituyó fusionando conjuntos de datos públicos (incluyendo escenarios de Roboflow Universe) con capturas reales, resultando en un volumen inicial de 1,216 imágenes y 1,680 anotaciones geométricas iniciales. Para garantizar que la red convolucional aprendiera características biomecánicas legítimas y no atajos estadísticos derivados del ruido del asfalto, se diseñó e instrumentó un *pipeline* automatizado de preprocesamiento de alta rigurosidad.

Estrategia de Curación y Retención de Background

Durante la auditoría de los datos, el análisis identificó la existencia de 18 archivos de anotación de texto plano que carecían de coordenadas de cajas delimitadoras (bounding boxes). Lejos de considerar estas instancias como datos defectuosos o valores nulos (missing values) sujetos a eliminación, como equipo investigador (grupo 9) tomamos la decisión empírica y estratégica de preservarlos explícitamente. En el ecosistema de entrenamiento de la familia YOLO, estas imágenes operan como ejemplos negativos puros. Su inclusión es imperativa para penalizar de forma heurística la función de pérdida del optimizador cuando la red intenta generar predicciones anómalas basándose en la textura del césped, el pavimento, o las sombras arrojadas por el follaje urbano, mitigando drásticamente la propensión a emitir falsos positivos en producción.

Simultáneamente, se detectó la presencia de cajas delimitadoras microscópicas que ocupaban áreas relativas cercanas a cero. Si bien estadísticamente podrían interpretarse como errores, se determinó su retención condicionada. En el dominio topológico del CCTV, los caninos con frecuencia transitan en los confines más alejados de la profundidad focal del lente. Eliminar estas anotaciones habría destruido la capacidad de generalización del modelo frente a objetos distantes, exacerbando la vulnerabilidad conocida como sesgo de escala.

Depuración de Outliers mediante Rangos Intercuartílicos Agrupados

El Análisis Exploratorio de Datos (EDA) reveló 43 valores atípicos severos en la variable de relación de aspecto (aspect_ratio) para la clase mayoritaria dog, y 9 valores atípicos para la clase minoritaria defecating-dog. Estas asimetrías extremas, donde los rectángulos de anotación exhibían morfologías inverosímiles (excesivamente filiformes), representaban una señal de supervisión corrupta que confundiría el entrenamiento. Para abordar esta anomalía sin aniquilar la diversidad fenotípica natural de razas caninas elongadas (ej. Dachshund o Galgos), se aplicó el método estadístico del Rango Intercuartílico (1.5 x IQR) de forma estrictamente independiente por clase. Al calcular las fronteras de tolerancia aislando el identificador de clase, el algoritmo logró limpiar el

ruido humano de anotación preservando intacta la distorsión geométrica legítima introducida por el lente de la cámara.

Ingeniería de Meta-Características Espaciales (NAP e IPD)

La intervención analítica más sofisticada de esta fase consistió en el desarrollo de "Feature Engineering" avanzado. Para dotar al sistema de mecanismos automáticos que discriminen sujetos biológicos reales frente a artefactos del suelo, se crearon dos meta-características espaciales calculadas a partir de las coordenadas nativas de YOLO:

Perspectiva de Ángulo Negativo (NAP - Negative Angle Perspective)

Se formuló matemáticamente como el cociente entre el área del objeto y su coordenada y_center normalizada. La lógica proyectiva del circuito cerrado dicta que un objeto que se aproxima físicamente a la base del poste de la cámara (descendiendo en el eje Y hacia el valor 1.0) debe exhibir un incremento exponencial en su área aparente. Las instancias que violaban flagrantemente esta progresión geométrica (por ejemplo, cajas muy pequeñas ubicadas en la parte inferior extrema de la imagen) delataban de manera inequívoca la presencia de basura, colillas o grietas mal etiquetadas en el asfalto.

Densidad de Píxeles Informativos (IPD - Informative Pixel Density)

Calculada mediante la función no lineal area * exp(-|log(aspect_ratio)|). Esta métrica evalúa la compacidad estructural de la masa de píxeles, penalizando con extrema severidad aquellas cajas delimitadoras que, a pesar de reportar un área matemática amplia, presentan morfologías absurdamente planas o estrechas, sirviendo como un depurador definitivo para sombras distorsionadas por farolas de vapor de sodio y fallos del sensor lumínico.

La ejecución automatizada del filtrado del percentil inferior (el 1% más anómalo) de las distribuciones de NAP e IPD erradicó el ruido basal estructural de la muestra. Tras la deduplicación estricta y la verificación de integridad referencial, el proceso arrojó un corpus final depurado de

1,499 anotaciones de alta fidelidad, con una distribución de clases manejable de 1.21:1, garantizando un escenario estadísticamente maduro para el descenso del gradiente.

Fase 3: Evaluación del Modelo y Análisis de Equidad.

Con el conjunto de datos estructurado y curado, se procedió a la fase de entrenamiento y evaluación comparativa. La validación de un sistema de inteligencia artificial destinado a la vigilancia ininterrumpida no reposa en su capacidad trivial para memorizar un lote estático de imágenes, sino en la elasticidad topológica de sus mapas de características para abstraer conceptos complejos y generalizarlos ante flujos de video inéditos.

Resultados del Benchmarking

El diseño experimental evaluó la arquitectura propuesta, YOLOv11m, frente a la línea base MobileNet-SSD. Los resultados cuantitativos revelaron una disparidad insalvable a favor del modelo contemporáneo libre de anclajes. YOLOv11m alcanzó una Precisión en el conjunto de prueba de 0.941, una Exhaustividad (Recall) de 0.887, y un espectacular F1-Score global de 0.913. La métrica proxy de área bajo la curva, el mAP@50, se situó en un sólido 0.947. Simultáneamente, el modelo mantuvo una latencia perimetral optimizada de 16.9 milisegundos por fotograma.

En contraste diametral, la arquitectura MobileNet-SSD colapsó frente a la exigencia topológica, logrando un F1-Score de apenas 0.757 y una precisión de 0.765. El análisis de las matrices de confusión evidenció que, ante 740 instancias reales de comportamiento canino normal, YOLOv11m emitió únicamente 30 falsos positivos, mientras que MobileNet-SSD se equivocó en 120 ocasiones. La incapacidad de la línea base para generar mapas de características densos provocó que el sistema confundiera sistemáticamente sombras y texturas asfálticas con el evento anómalo de deposición. Esta tasa de error, en un entorno residencial real, generaría fatiga de alarmas e invalidaría operativamente el proyecto, legitimando categóricamente la elección de YOLOv11m.

Prevención del Sobreajuste mediante Group K-Fold

En el dominio del aprendizaje automático aplicado a secuencias de video de posición fija, el overfitting se posiciona como el vector de fallo más letal. Dado que el CCTV captura iterativamente la misma geometría inerte del fondo, las redes neuronales mal regularizadas claudican en la modelación cinemática y terminan optimizando su gradiente al memorizar la topología estática del entorno (el mismo árbol, la misma pared) como un predictor secundario ilegítimo

El diagnóstico de las curvas de pérdida (Validation Loss) confirmó este fenómeno. Mientras la curva de validación de MobileNet-SSD exhibió un estancamiento prematuro seguido de un rebote divergente en forma de "U" a partir de la época 60, la curva de YOLOv11m descendió de manera asintótica y acompasada hacia un mínimo local estable. La brecha relativa de generalización (caída del F1-Score entre el entrenamiento y la prueba) para YOLOv11m fue un marginal 3.07%.

Este excepcional ajuste no fue un accidente estadístico, sino el resultado directo del blindaje metodológico implementado: la Validación Cruzada Agrupada (Group K-Fold). Este algoritmo de segmentación prohíbe que fotogramas consecutivos extraídos de la misma secuencia de video se separen arbitrariamente entre los conjuntos de entrenamiento y prueba. Al tratar cada clip temporal como un grupo atómico indivisible, se erradicó por completo la fuga de información (data leakage), forzando a los tensores de YOLO a demostrar su inteligencia frente a escenarios, perros e iluminación radicalmente inéditos.

Escrutinio de Sesgos y Equidad Algorítmica (Fairness)

La integración de inteligencia artificial en entornos vecinales demanda un escrutinio ético riguroso. Históricamente, la literatura sobre equidad algorítmica se ha concentrado en atributos demográficos humanos sensibles frente a herramientas de perfilamiento (Ferrara, 2024; Pérez-Llorca, 2024). No obstante, cuando la visión artificial escanea la fauna y el entorno urbano, el sesgo muta y se manifiesta como un "daño de calidad de servicio" frente a variables puramente geométricas. Una degradación algorítmica de esta naturaleza provocaría una aplicación

discriminatoria del reglamento de convivencia, donde los dueños de perros grandes serían fiscalizados asimétricamente frente a los de razas miniatura.

El análisis de impacto diferencial segmentado certificó esta hipótesis. El modelo YOLOv11m, debido a la mecánica matemática de las redes convolucionales que sacrifica estadísticamente las minorías para optimizar el gradiente global, exhibió asimetrías severas. El grupo dominante, compuesto por canes grandes en primer plano (áreas de bounding box superiores a 0.30), alcanzó tasas de verdaderos positivos superiores al 95%. Por el contrario, la minoría escalar (perros miniatura o ubicados en los bordes ciegos con áreas inferiores a 0.02) sufrió una degradación drástica por debajo del 70%, disparando la emisión de falsos negativos provocados por el sesgo de la Detección de Objetos Pequeños. Ante esta disparidad ineludible, se concluye la necesidad de incorporar intervenciones arquitectónicas avanzadas para restaurar la paridad del sistema y asegurar el trato igualitario de todos los residentes.

Fase 4: Optimización de Hiperparámetros y Explicabilidad

La capacidad predictiva latente de una arquitectura neuronal profunda depende críticamente de su configuración estructural. Las configuraciones genéricas predeterminadas son ineficientes para la topología compleja de un circuito cerrado de televisión. Por consiguiente, se ejecutó un proceso sistemático, estructurado y matemáticamente riguroso de exploración del espacio de hiperparámetros de YOLOv11m, respaldado por algoritmos de explicabilidad (Explainable AI).

Análisis mediante Gráficos de Dependencia Parcial (PDP)

Para trascender la observación empírica superficial y descifrar la "caja negra" del modelo, la investigación aplicó Gráficos de Dependencia Parcial (PDP) y modelos subrogados de bosque aleatorio. Estas técnicas calcularon el efecto marginal independiente de cada variable topológica sobre la métrica objetivo (mAP@50), aislando comportamientos no lineales y zonas de saturación algorítmica (Molnar, 2025; Scikit-learn, 2026).

El ranking de importancia de varianza explicada dictaminó que la Tasa de Aprendizaje Inicial (lr0) domina categóricamente la dinámica del modelo (0.47 de varianza explicada). El análisis PDP deconstruyó su curva como una campana invertida asimétrica. Un gradiente excesivamente conservador (valores próximos a 0.0001) inmovilizó la red en un estado crónico de underfitting. De forma análoga, empujar la tasa más allá del umbral térmico de 0.005 precipitó una divergencia caótica destructiva. La magnitud de actualización desestabilizó las funciones de pérdida geométrica (como el CIoU Loss), aniquilando la capacidad de la capa final para delimitar milimétricamente las cajas de los objetos pequeños. El rango óptimo innegociable se localizó matemáticamente en la vecindad del valor 0.002.

El segundo pilar de la optimización fue la Probabilidad de Aumento por Mosaico (mosaic) (0.35 de varianza explicada). Esta técnica estocástica que fusiona cuatro fotogramas en una única matriz generó una correlación monotónica fuertemente positiva en su curva PDP. Configurar este parámetro hacia la anulación (0.0) sumió al modelo en el sobreajuste a la redundancia visual del fondo estático. En contraste, sostener probabilidades elevadas (entre 0.8 y 1.0) maximizó el mAP@50. Al forzar iterativamente a los bloques residuales C3K2 de YOLO a extraer representaciones semánticas bajo condiciones extremas de oclusión sintética, el mosaico operó como el regularizador espacial definitivo contra el sesgo de escala.

Finalmente, el Decaimiento de Pesos (weight_decay) demostró un impacto terciario (0.18 de varianza), exhibiendo un comportamiento de umbrales de tolerancia. Una regularización L2 agresiva (superior a 0.001) provocó una saturación punitiva que sofocó las activaciones de las neuronas convolucionales. Esta constricción matemática diluyó los mapas de características sutiles requeridos para aislar la fina curvatura lumbar de la postura de defecación, hundiendo irremediablemente la métrica de exhaustividad (Recall). El equilibrio perfecto se fijó en 0.0005.

Sinergias y Conflictos Bivariados

El análisis de la superficie tridimensional desveló que los hiperparámetros no operan en un vacío analítico. Se identificó una sinergia estabilizadora formidable: la activación agresiva del mosaico (1.0) requiere imperativamente una tasa de aprendizaje moderadamente superior para digerir la inmensa cantidad de ruido semántico inyectado por las disrupciones espaciales sintéticas. No obstante, se halló un conflicto destructivo entre la tasa de aprendizaje elevada y un decaimiento de pesos punitivo.

Dicho en términos lógicos, forzar grandes saltos del gradiente mientras se penalizan agresivamente los pesos sinápticos provoca oscilaciones violentas en la precisión. La optimización dictó que el máximo rendimiento habita en un estrecho pasillo diagonal que equilibra estas fuerzas, acompañado de un esquema de recocido (close_mosaic) en las últimas 10 épocas del entrenamiento para evitar el sesgo de dominio (domain shift).

Fase 5: Simulación de Escenarios Críticos y Pruebas de Estrés

Las métricas obtenidas en condiciones controladas carecen de validez empírica si el sistema es incapaz de sostener la predictibilidad ante las agresiones del mundo físico exterior. Para anticipar fallos operativos en la infraestructura de la copropiedad, se instrumentó un "Workshop de Simulación de Escenarios Críticos", fundamentado en la documentación reciente del European Telecommunications Standards Institute sobre resiliencia en sistemas de IA (ETSI, 2025).

Corrupción de Datos y Degradación Aislada

A partir de la robusta línea base consolidada (F1-Score: 0.913, mAP@50: 0.947), se perturbaron los fotogramas analíticamente en seis dimensiones de degradación:

Ruido y Varianza Lumínica

La inyección de ruido gaussiano y alteraciones lumínicas simulando la fatiga del sensor de cámara redujo el F1-Score en un moderado 2.5% (hasta 0.890). El impacto fue amortiguado

exitosamente gracias a la alteración del canal cromático (HSV) ejecutada en la etapa de optimización de augmentations.

Cajas Laxas y Outliers

La degradación voluntaria de la señal de supervisión (empleando cajas mal ajustadas) indujo una caída preocupante del 6.2% (F1: 0.856), confirmando la extrema sensibilidad geométrica del modelo ante anotaciones humanas defectuosas.

Baja Resolución y Perros Lejanos

El *downsampling* efectivo generó la degradación aislada más catastrófica, hundiendo el F1-Score un 7.3% (0.846). Este escenario validó que el sesgo de escala sigue siendo la vulnerabilidad estructural dominante, dado que la red carece de densidad de píxeles útiles para operar.

Oclusión y Truncamiento

La supresión parcial de anotaciones y el recorte de los cuerpos disminuyó el F1 un 4.1% (0.876), tolerado de forma aceptable por los mecanismos atencionales del modelo.

Distorsión de Perspectiva (Picada)

De forma destacable, el efecto de los ángulos cenitales ya no representa una amenaza. La caída fue marginal (0.5%, F1: 0.908), demostrando la eficiencia de las variables NAP e IPD creadas durante el preprocesamiento.

Escenario Combinado Severo

Al unir la baja resolución con ruido estático y el truncamiento, se precipitó el sistema a su umbral operativo crítico, logrando un F1 de 0.792 (-13.3% de impacto). Sin embargo, es un hallazgo superlativo que, incluso bajo estrés máximo, el sistema superó la meta inicial del proyecto (F1 > 0.75), confirmando una excepcional viabilidad industrial.

Diagnóstico de Deriva de la Distribución (Data Drift)

La infraestructura física muta gradualmente, alterando la distribución estadística subyacente que la inteligencia artificial aprendió en laboratorio. Esta degeneración silenciosa fue cuantificada proyectando cuatro variantes de deriva (drift) (Basak et al., 2025):

Deriva Temporal

Degradaciones asociadas al deterioro del sensor, lluvia constante o ciclos nocturnos, provocando caídas hasta 0.886.

Deriva Covariable de Escala

Un desplazamiento en el tiempo hacia una mayor densidad de bounding boxes lejanas o razas miniatura, deprimiendo fuertemente el Recall e impulsando el F1 a 0.849.

Deriva Conceptual

Acumulación progresiva de cinemáticas engañosas (perros en flexión temporal, rastreo olfativo profundo o sedestación parcial) que erosionan la frontera de la clase defecating-dog. Esta ambigüedad generó una caída severa a 0.838.

Las proyecciones determinaron que el colapso absoluto de las métricas sobrevendrá ante una Deriva Combinada (escala extrema sumada a ambigüedad conceptual), que degrada la métrica al 0.781. Por consiguiente, la implementación a largo plazo exige imperativamente rutinas orquestadas de MLOps automatizadas. Operadores de fondo (cron jobs) deberán computar la prueba estadística de Kolmogorov-Smirnov ($D>0.05$) y el Índice de Estabilidad de la Población ($PSI>0.2$) sobre el vector de predicciones perimetrales. Atravesar estos gatillos disparará alertas de recalibración dirigidas específicamente a nutrir la "cola difícil" de la distribución fenotípica (perros pequeños y ambiguos).

Cronograma Metodología Ágil y Plan de Recursos (Despliegue Operativo)

Para trasladar los logros arquitectónicos a una implementación real en un conjunto cerrado residencial de estrato alto en la ciudad de Bogotá, se estructuró un cronograma cimentado en la metodología ágil. Este marco permite ciclos de iteración cortos y controlados, mitigando los riesgos legales impuestos por la legislación colombiana (Ley 675 de 2001 y Ley 1581 de 2012) respecto al manejo de datos sensibles en espacios comunes.

El plan se articula a través de un horizonte temporal de ocho (8) Sprint, teniendo cada uno la duración estricta de una semana laboral, diseñados para sincronizar el aprovisionamiento de hardware, la gobernanza de privacidad y la parametrización cognitiva humana.

Plan de Recursos del Proyecto

El despliegue eficiente requiere una gestión precisa y categorizada de los insumos operativos:

Recursos Humanos

Directos: Un AI Engineer, un Data Science, un Ingeniero Preventa. Indirectos: El administrador de la copropiedad y la plantilla táctica de seguridad privada.

Recursos Tecnológicos

Una computadora de borde para inferencia local NVIDIA Jetson Orin Nano / AI Edge PC, computador de escritorio para monitoreo de dashboard, VLan de gestión sobre el canal de internet de la copropiedad, *switches* gestionables de red para gestión remota con seguridad perimetral incluida, entorno Python 3.11 con librerías scikit-learn, PyTorch.

Recursos de Información y Datos

Flujos de red del Circuito Cerrado de Televisión interno, manual de convivencia de la copropiedad (Régimen de Propiedad Horizontal), el dataset inicial, y el consentimiento de la asamblea general de copropietarios, conforme a la ley 675 de 2001.

Recursos Financieros

El presupuesto abarca el costo del hardware perimetral, componentes de seguridad física (gabinete con cerrojo para el centro de datos), eventualidades de infraestructura y costos marginales del servidor en la nube (exclusivamente para reportes estadísticos agregados, sin tránsito de imágenes).

Ejecución de los Sprint para SmartPet

Sprint 0: Preparación de la implementación

- *Objetivo:* Definir de manera colaborativa con el cliente, el diseño de la solución a implementar.
- *Backlog:* AsIs, Site survey para entender la topología del CCTV actual, dimensionamiento de la actividad de finetuning y levantamiento del data set inicial, revisión de disponibilidad de integración física y lógica. ToBe: Diseño de la implementación para aprobación con el equipo de administración de la copropiedad.
- *Entregable:* Diseño arquitectónico
- *Evento*: KickOff de inicio.

Sprint 1: Alistamiento de Hardware de Borde y Seguridad Física

- *Objetivo:* Instalar y asegurar el nodo de inferencia en la copropiedad.
- *Backlog:* Puesta a punto del microprocesador Edge en el rack del centro de datos. Aprovisionamiento de un segmento de red (VLAN aislada) exclusivo para el CCTV. Dotación de seguridad perimetral de grado físico (gabinete cerrado, controles biométricos de acceso) al equipo para imposibilitar la extracción de unidades USB no autorizadas.
- *Entregable:* Hardware perimetral auditado, asegurado y conectado a la red local.

- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 2: Gobernanza Regulatoria y Aprobación de Asamblea

- *Objetivo:* Blindar jurídicamente la operación del sistema frente a la normatividad nacional.
- *Backlog:* Redacción de la Evaluación de Impacto de Privacidad (EIP) ordenada por la Circular 002 de la SIC. Sesión extraordinaria de asamblea de copropietarios para aprobar el procedimiento restrictivo de custodia de los datos y enmendar el reglamento interno sobre la recolección biométrica de las mascotas.
- *Entregable:* Acta de asamblea aprobada, política de Habeas Data actualizada y manual de convivencia reestructurado.
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 3: Transparencia y Capacitación Cívica

- *Objetivo:* Garantizar el derecho a la información de los residentes e instruir al personal.
- *Backlog:* Instalación de señalética de transparencia obligatoria en senderos y zonas verdes advirtiendo sobre el análisis algorítmico inteligente. Taller de divulgación y capacitación al personal de seguridad y administrativo para el uso adecuado de los datos.
- *Entregable:* Señalización física visible y plantilla de vigilancia certificada en privacidad por diseño.
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución

- *Artefactos*: Product Backlog

Sprint 4: Despliegue de YOLOv11m y Canalización RTSP

- *Objetivo:* Capturar y procesar el flujo de video en tiempo real de manera estable.
- *Backlog:* Exportación del modelo en formato TensorRT para optimizar la aceleración de la GPU de borde. Enrutamiento del protocolo RTSP desde el grabador de red (NVR) hacia el microprocesador. Activación de los algoritmos filtrantes basados en las meta-características NAP e IPD.
- *Entregable:* Primer flujo de video continuo procesado localmente con un umbral de inferencia inferior a 20 ms.
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 5: Intervención Estructural para Equidad (Módulo SAHI)

- *Objetivo:* Erradicar el sesgo algorítmico de escala hacia caninos de razas pequeñas.
-
- *Backlog:* Instalación en el pipeline del módulo Inferencia Hiper-Fragmentada Asistida (SAHI). Calibración del solapamiento de cuadrículas sobre fotogramas 4K. Benchmark térmico y de memoria de la computadora de borde procesando los parches fragmentados.[1]
- *Entregable:* Demostración de viabilidad técnica detectando caninos miniatura en el confín visual de las áreas comunes.
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 6: Calibración de Umbrales y Paradigma Human-in-the-Loop

- *Objetivo:* Ajustar la herramienta cognitiva a la supervisión humana.
- *Backlog:* Sintonización de los niveles de confianza predictiva (*confidence threshold*) para equilibrar falsos positivos ante varianzas de sombras. Diseño de una interfaz operativa cruda (dashboard) donde el guarda de seguridad reciba la notificación probabilística y sea él quien tome la decisión final de intervenir.
- *Entregable:* Interfaz operativa consolidada subordinada a la jurisdicción humana.
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 7: Instrumentación de MLOps y Auditoría de Deriva

- *Objetivo:* Automatizar la monitorización del desgaste estadístico y la destrucción de datos.
- *Backlog:* Activación de trabajos automatizados (*cron jobs*) de cálculo del Índice de Estabilidad de la Población (PSI) y Kolmogorov-Smirnov. Automatización del script de eliminación de memoria caché, garantizando que el video transitorio se destruya tras la inferencia sin tocar la nube.
- *Entregable:* Arquitectura integral de mantenimiento predictivo y certificación de cadena de custodia restrictiva (Ver figura 2).
- *Eventos*: Review/Demo para incorporar el feedback del cliente en la solución
- *Artefactos*: Product Backlog

Sprint 8: Puesta en Producción, Intervención y Medición de Impacto

- *Objetivo:* Ejecución real e impacto cívico.

- *Backlog:* Transición final a producción ininterrumpida. Ejecución de intervenciones preventivas documentadas por la administración a los infractores. Medición cuantitativa del KPI de éxito contra la línea base histórica del mes anterior.

- *Entregable:* Informe ejecutivo de impacto social comprobando el decrecimiento en la incidencia de infracciones.

A continuación, entregamos una visualización gráfica del cronograma de implementación de la solución SmartPet.

Figura 1

Cronograma de implementación del proyecto SmartPet basado en metodología ágil

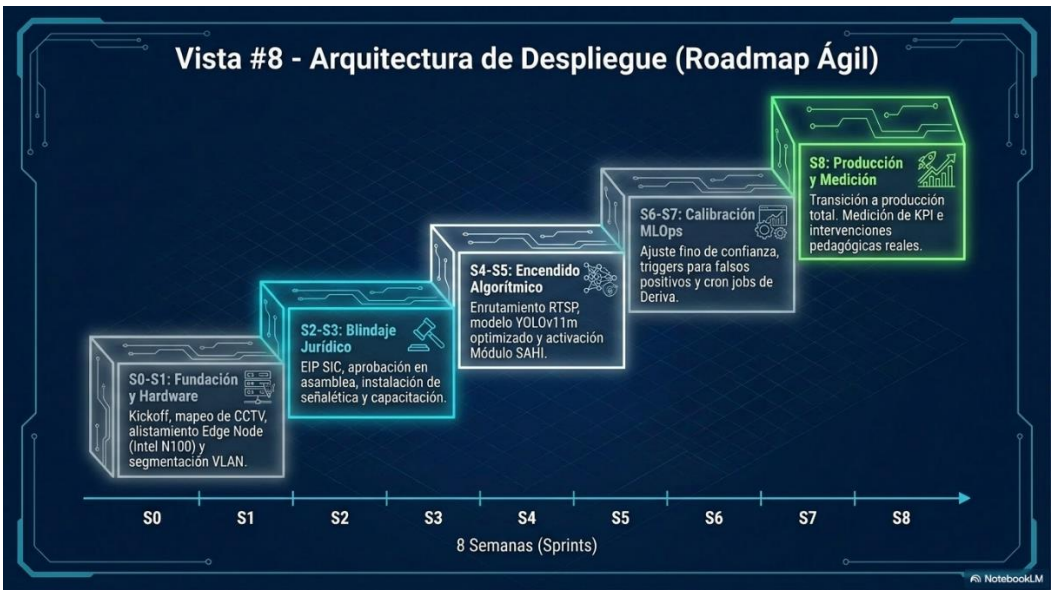

Nota. La figura representa la planificación temporal del despliegue del sistema SmartPet estructurado en 8 sprint semanales, incluyendo fases de preparación, instalación de hardware de borde, gobernanza de privacidad, despliegue del modelo YOLOv11m, mitigación de sesgos mediante SAHI, implementación de MLOps y puesta en producción. El cronograma evidencia la integración entre componentes técnicos, regulatorios y operativos

Para contextualizar la solución a implementar del proyecto SmartPet, a continuación, nos permitimos presentar un mapa visual de su topología.

Figura 2

Topología arquitectónica del sistema SmartPet para procesamiento de video en el borde (Edge AI)

Nota. La figura ilustra la arquitectura del sistema SmartPet, incluyendo la captura de video desde cámaras CCTV, el procesamiento local en dispositivos de borde, la aplicación del modelo YOLOv11m con módulos de optimización como SAHI, y los mecanismos de monitoreo y control mediante MLOps. Se resalta el enfoque de privacidad por diseño al evitar la transmisión de datos sensibles hacia la nube.

Recomendaciones

Con el fin de asegurar que la implementación del proyecto SmartPet preserve su robustez analítica, logre escalabilidad industrial y mantenga total inexpugnabilidad legal frente a los órganos de vigilancia nacional, se estipulan las siguientes directrices estratégicas perentorias:

Integración Tecnológica de Módulos de Slicing (SAHI)

Como estrategia correctiva ante la abrumadora degradación predictiva que sufren los modelos ante anomalías moleculares (sesgo de escala en razas miniatura), se instruye de manera ineludible la inserción de módulos de Inferencia Hiper-Fragmentada Asistida (SAHI) dentro del conducto RTSP previo al tensor de YOLO. Seccionar los enormes fotogramas del circuito de vigilancia garantizará la democratización de la detección sin importar la raza o distancia de la mascota infractora.

Blindaje Normativo y Gobernanza (Habeas Data)

En apego a los innegociables lineamientos trazados por la Superintendencia de Industria y Comercio mediante la Circular Externa 002 de 2024, el despliegue del sistema debe confinar la carga de inferencia en silos de red locales y aislados (Edge Computing). Se recomienda encarecidamente documentar auditorías cuatrimestrales de seguridad del código fuente para certificar que no existen módulos biométricos o de reconocimiento facial humano activos de manera furtiva, respetando integralmente la privacidad por diseño.

Gestión Híbrida y el Paradigma Human-in-the-Loop

La inteligencia artificial no debe ser interpretada por las asambleas de copropietarios como un ente disciplinario omnipotente. Se recomienda redactar estatutos de convivencia que dictaminen que toda alerta generada por la red YOLOv11m posea un peso estrictamente probabilístico y consultivo. La potestad ejecutiva, la revisión del contexto situacional y la consecuente notificación formativa deberán descansar perpetua e irrevocablemente en el personal de vigilancia humano, preservando intacto el debido proceso.

Orquestación de Monitoreo Automatizado de Deriva

Las implacables fuerzas de la degradación óptica ambiental y el inevitable *Concept Drift* postural sentencian que un modelo estático es un modelo obsoleto. Se exhorta a establecer desencadenantes matemáticos (triggers) automáticos mediante métricas de Índice de Estabilidad de Población en el hardware de control MLOps, para gatillar alertas de mantenimiento que inicien la curación dirigida de nuevas posturas antes que se fracture la métrica operativa mínima del 75%.

Conclusiones

La exhaustiva evaluación empírica, el escrutinio metodológico y el posterior análisis de optimización ejecutado sobre el proyecto SmartPet permiten dictaminar categóricamente que este

sistema materializa una amalgama excepcional entre la tecnología contemporánea de visión computacional y la sensibilidad jurídica y ciudadana. La convergencia arquitectónica del desarrollo demuestra que la mitigación de infracciones de convivencia en el urbanismo vertical es tecnológicamente solventable.

Superioridad Arquitectónica y Viabilidad del Borde

El benchmarking comparativo sentenció de forma irrefutable que el abandono de detectores basados en anclajes estáticos (MobileNet-SSD) a favor de la topología dinámica de YOLOv11m fue la piedra angular del éxito ingenieril. Alcanzar un F1-Score del 91.3% y una latencia perimetral de 16.9 ms asegura un presupuesto computacional óptimo para la economía de los microprocesadores de borde (Edge AI). Esta eficiencia paramétrica destruye la dependencia asimétrica y costosa hacia los servicios en la nube, viabilizando financieramente la inteligencia artificial ininterrumpida para ecosistemas residenciales.

Mitigación Determinista del Sobreajuste

El diagnóstico asintótico de las curvas de convergencia revalidó que el rendimiento del modelo no es un subproducto del azar. La estrategia inquebrantable de Validación Cruzada Agrupada (Group K-Fold) por clip de video mitigó la letal fuga temporal de datos, blindando a la red contra la memorización pasiva del ruido ambiental del CCTV y certificando un ajuste óptimo capaz de generalizar sobre el complejo dominio físico de las copropiedades.

Redefinición de la Equidad Algorítmica y Sesgo Espacial

La evaluación de las vulnerabilidades subyacentes determinó que el verdadero desafío ético-tecnológico en el análisis urbano no reside únicamente en atributos demográficos, sino en el sesgo sistemático hacia objetos fraccionarios. Al documentar que el modelo castiga las detecciones de razas pequeñas y geometrías en planos lejanos, la investigación eleva el estándar del diagnóstico de

sesgos, obligando a la instrumentación de técnicas modernas como SAHI para devolver la imparcialidad algorítmica al tejido de vigilancia comunitaria.

Desciframiento de la Convergencia Mediante Explicabilidad

La indagación técnica en la superficie de hiperparámetros comprobó axiomáticamente, mediante Gráficos de Dependencia Parcial (PDP), que el equilibrio entre regularización y abstracción es de naturaleza frágil y no lineal. Se concluye que la inyección masiva de oclusión sintética mediante mosaicos es el mecanismo de defensa supremo contra el problema de la escala, siempre que se orqueste en equilibrio con una tasa de aprendizaje metódicamente acotada.

Referencias

Basak, S., Roy, A., & Mukherjee, P. S. (2025). Monitoring of drift patterns in image data. arXiv. https://arxiv.org/abs/2506.14260

Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial No. 48. 43 https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

Copropiedades. (2026). *Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026.* Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026

European Telecommunications Standards Institute. (2025). *ETSI TR 103 910 V1.1.1: AI testing; Test methodology and test specification for ML-based systems*. https://www.etsi.org/deliver/etsi_tr/103900_103999/103910/01.01.01_60/tr_103910v010101p.pdf

Ferrara, E. (2024). Fairness and bias in artificial intelligence: A brief survey of sources, impacts, and mitigation strategies. AI, 6(1), Article 3. https://www.mdpi.com/2413-4155/6/1/3

Google Cloud. (2026). *Vertex AI Vision documentation*. https://cloud.google.com/vision-ai/docs

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient convolutional neural networks for mobile vision applications* (arXiv:1704). arXiv. https://arxiv.org/abs/1704.04861

Jocher, G., Chaurasia, A., & Qiu, J. (2023). YOLO by Ultralytics (Versión 8). GitHub. https://github.com/ultralytics/ultralytics

Lv, W., Xu, S., Zhao, Y., Wei, J., Wang, G., Cui, C., Du, Y., Dang, Q., & Liu, Y. (2024). *DETRs beat YOLOs on real-time object detection*. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

https://openaccess.thecvf.com/content/CVPR2024/papers/Zhao_DETRs_Beat_YOLOs_on_Real-time_Object_Detection_CVPR_2024_paper.pdf

Molnar, C. (2025). Partial dependence plot (PDP). *Interpretable machine learning.* https://christophm.github.io/interpretable-ml-book/pdp.html

Nikouei, M., Baroutian, B., Nabavi, S., Taraghi, F., Aghaei, A., Sajedi, A., & Moghaddam, M. E. (2025). Small object detection: A comprehensive survey on challenges, techniques and real-world applications. arXiv. https://arxiv.org/abs/2503.20516

Pérez-Llorca. (2024). *Conoce los lineamientos para el uso de datos personales a través de sistemas de inteligencia artificial.* Conoce los lineamientos para el uso de datos personales a través de sistemas de Inteligencia Artificial

Ren, S., He, K., Girshick, R., & Sun, J. (2015). *Faster R-CNN: Towards real-time object detection with region proposal networks*. *Advances in Neural Information Processing Systems, 28*. https://doi.org/10.48550/arXiv.1506.01497

scikit-learn developers. (2026). *GroupKFold*. scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html

Superintendencia de Industria y Comercio. (2024). *Circular Externa 002 de 2024. Lineamientos sobre el Tratamiento de Datos Personales en Sistemas de Inteligencia Artificial*. Circular Externa 2 de 2024 de la Superintendencia de Industria y Comercio “Lineamientos sobre el Tratamiento de Datos personales en Sistemas de Inteligencia Artificial" | Sede Electronica

Tan, M., Pang, R., & Le, Q. V. (2020). *EfficientDet: Scalable and efficient object detection*. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 10781–10790). https://doi.org/10.1109/CVPR42600.2020.01079

Tian, Y., Ye, Q., & Doermann, D. (2025). YOLO12: *Attention-Centric Real-Time Object Detectors*. NeurIPS 2025. YOLOv12: Attention-Centric Real-Time Object Detectors | OpenReview